

基于 CNN - LSTM 神经网络的磁盘故障预测方法

彭福康¹ 王恩东² 高晓锋¹

¹(郑州大学信息工程学院 河南 郑州 450001)

²(浪潮电子信息产业股份有限公司 山东 济南 250101)

摘 要 运维人员准确预测将要发生的磁盘故障是保障数据安全的关键。然而,不平衡数据、不准确磁盘特性标记影响预测的准确性。提出一种基于预故障重置窗口(pre_Failure Reseting Window, pre_FRW) 数据处理并组合卷积神经网络(CNN) 和长短期记忆网络(LSTM), 即 pre_FRW-CNN-LSTM 的磁盘故障预测方法。pre_FRW 数据处理既可以解决样本不平衡, 又能减少潜在的模糊样本。而 CNN-LSTM 模型结构能提取数据的空间特征, 还能有效捕捉时间序列之间的依赖关系。在真实监控数据集上实验表明, pre_FRW-CNN-LSTM 的磁盘故障预测方法对比业界其他方法提升 2% ~ 10% 的故障预测率, 并保持较低的错误告警率。

关键词 云数据中心 预故障重置窗口 截断窗口 卷积神经网络 长短期记忆网络 磁盘故障预测

中图分类号 TP3 文献标志码 A DOI: 10.3969/j.issn.1000-386x.2024.06.014

A DISK FAILURE PREDICTION METHOD BASED ON CNN - LSTM NEURAL NETWORK

Peng Fukang¹ Wang Endong² Gao Xiaofeng¹

¹(School of Information Engineering, Zhengzhou University, Zhengzhou 450001, Henan, China)

²(Inspur Electronic Industry Co., Ltd., Jinan 250101, Shandong, China)

Abstract Accurate prediction from operation and maintenance personnel of the upcoming disk failure is the key to ensure data security. However, unbalanced data and inaccurate disk characteristic marking affect the accuracy of prediction. This paper proposes a disk failure prediction method based on pre_Failure Reseting Window (pre_FRW) data processing and combining convolutional neural network (CNN) and long short-term memory network (LSTM), namely pre_FRW-CNN-LSTM. The pre_FRW data processing could not only solve the sample imbalance, but also reduce the potential fuzzy samples. The CNN-LSTM model structure could extract the spatial characteristics of the data, and it could also effectively capture the dependencies between time series. Experiments on real monitoring data sets show that the disk failure prediction method of pre_FRW-CNN-LSTM improves the failure prediction rate by 2% - 10% compared with other methods in the industry and maintains a low false alarm rate.

Keywords Cloud data center Pre-failure reseting window Cutting window CNN LSTM Disk failure prediction

0 引 言

随着信息技术的快速进步、通信网络的迅猛发展, 互联网产生的数据总量呈现爆发式增长, 这些数据多数存储在企业的云数据中心中。云数据中心存储系统故障会给企业及服务者造成不可挽回的损失, 因此数据安全是企业考虑的第一要素。腾讯云在 2018 年发

生存储故障, 一家初创公司由于公众号的存储数据全部丢失而倒闭。存储系统的复杂结构和庞大体量使得存储系统故障成为常态, 其中磁盘故障是最常见的一种^[1]。据估计, 磁盘故障占云数据中心硬件替换的 78%^[2]。如果能提前预测出磁盘要发生故障, 那么运维人员能针对性对故障进行处理。比如备份数据、更换要故障的磁盘, 维护存储系统的正常运行, 保障数据的安全。

收稿日期: 2020 - 12 - 24。国家重点研发计划项目(2017YFB1001700)。彭福康, 硕士生, 主研领域: AIOps 智能运维。王恩东, 中国工程院院士。高晓锋, 博士生。

为了提前预测磁盘即将发生的故障,绝大多数现代存储磁盘都配备了自我监控、分析和报告技术(Self-Monitoring Analysis and Reporting Technology, SMART)。它可以监控磁盘的输出属性,这些属性包含磁盘状态变化的信息。因此,SMART 本身提供了预测即将发生的磁盘故障的能力。即在磁盘失败之前,如果任何属性超过制造商定义的阈值,将发出警告信息^[3]。然而,由于该方法简单且阈值设置保守,故障预测率仅为3%~10%,错误告警率为0.1%^[4]。

在过去的几十年里,许多研究者提出了多种方法来提高磁盘预测的准确性。已有的研究工作主要采取统计学习(比如秩和检验^[5]、朴素贝叶斯^[6]等)、机器学习(比如支持向量机^[7]、分类树^[8]、反向传播^[9]、随机森林^[10]等),这些传统的方法取得了一定的成果。近几年来,深度学习技术由于其处理大量数据的优势而开始应用到磁盘故障预测领域。循环神经网络(Recurrent Neural Network, RNN)、长短期记忆网络(Long-Short Term Memory, LSTM)等单一神经网络在磁盘故障预测上取得一定成果。尽管在许多研究者进行了广泛的研究,但在复杂的云数据环境中,进行磁盘故障预测仍然面临实际挑战。分析原因有以下几点:

(1) 磁盘数据集属性众多。如何合理地从属性值中选择与磁盘状态相关联的属性,去除无关及冗余属性,是影响预测效果的一大因素。

(2) 磁盘数据样本固有的严重不均衡性。故障样本占样本总数的比例较低,如果不做有效的数据平衡,使得学习模型容易陷入过拟合,降低模型泛化能力。

(3) 不准确的标签。现有研究通常将故障发生时刻标记为唯一的正样本^[11-12]。然而,现场研究报告表述,故障发生时刻之前存在潜在的异常,如潜在的扇区错误^[13]和故障慢速症状^[14]。这种故障发生前的异常也应标记为正样本,以便更准确地反映失败模式。

1 相关工作

云数据中心为了保证稳定运行,从存储系统中采集的真实数据往往有严重的不平衡问题,所以数据前处理是磁盘故障预测极其重要的一部分。文献[1, 15]使用再平衡技术即随机欠采样和过采样获得平衡数据集,但忽视了标签不准确问题,故障样本前一定时间内的数据样本状态接近于异常,健康样本截止时间前存在故障的可能。文献[17]将磁盘属性值按照数据分布大小进行符号化处理,文献[18]将原始属性值处理成健康度表示,这两者都是将原始特征值的变化情况简化成其他表示,但预测性能依赖聚类结果准确

性。文献[11-12]只是将故障当天标记为正样本,忽略磁盘即将故障时磁盘特性的缓慢变化和健康磁盘模糊标记的问题。

在模型方法方面,文献[6]选择朴素贝叶斯来预测故障情况,但这个方法只局限于特定的故障类型。文献[7]选择支持向量机等机器学习方法进行预测实验,虽然可以达到较高的精确度,但是故障检测率(即召回更多正样本)只有67%。文献[8]选择分类与回归树模型预测磁盘故障,在低错误告警率的情况下,故障预测率仍然不理想。在语言模型、语音识别、机器翻译中,循环神经网络已被证明是获取时间序列依赖性的有效工具,而近几年来以循环神经网络为基础的深度学习方法在磁盘故障预测方面成为主流。文献[17]对磁盘数据符号化,使用LSTM的网络进行故障预测,平均精度为83%。文献[18]在健康度评估之后,也使用LSTM的预测网络,预测性能达到最佳91%的故障预测率和0.3%的错误告警率。文献[19]采用无监督学习方法,利用LSTM加全连接层(FC)的网络作为预测模型,最终得到81%的准确率和86%的召回率。

文献[20]提出卷积神经网络(CNN)的结构,在图片分类领域取得的效果引起行业巨大的轰动。近几年来,CNN空间特征提取的良好效果使得研究者们将其应用到时间序列中。文献[21]将单变量网络流量映射成二维图像,并通过CNN提取图像的特征。文献[22]提出了一个张量方案,利用多元CNN来分类多维时间序列。这些方法从时间序列中有效提取空间特征,提高分类器的性能。但文献[15]中指出,从时间序列中提取空间特征时,卷积层和池化层可能会发生时间信息丢失,需要合理的参数设置。

在上述工作中,磁盘故障预测问题取得了一定进展,但还存在属性值不合理的特征选择、不准确的标签及单一模型未能学习到时序数据所有的特征模式等问题。本文基于信息增益比率的方法选择特征,提出的pre_FRW数据处理方法正确标注数据并增加正样本平衡数据集。基于磁盘时序数据的LSTM网络有效获取时间依赖性并得到良好性能效果,借鉴CNN优秀的空间特征提取性能,本文提出了pre_FRW-CNN-LSTM的磁盘故障预测方法。在真实云数据中心的数据集上,此预测方法获得了更好的性能表现。

2 方法设计

2.1 模型结构示意图

本文首先对原始数据做数据清洗工作,选择一段

时间序列数据,删除空值单值高的特征,填充缺失值,去除运行天数少的磁盘等。其次采用信息增益比率的特征选择方法,降序排序选择前 10 个特征。接着采用提出的 pre_FRW 数据处理方法,故障磁盘预故障窗口内样本标记为正,健康磁盘截断窗口内样本截断丢弃。最后做滑动窗口的处理,处理后的数据作为输入数据,输入到 CNN-LSTM 的深度学习神经网络结构中,训练样本得到预测结果。基于 pre_FRW-CNN-LSTM 的磁盘故障预测模型如图 1 所示。

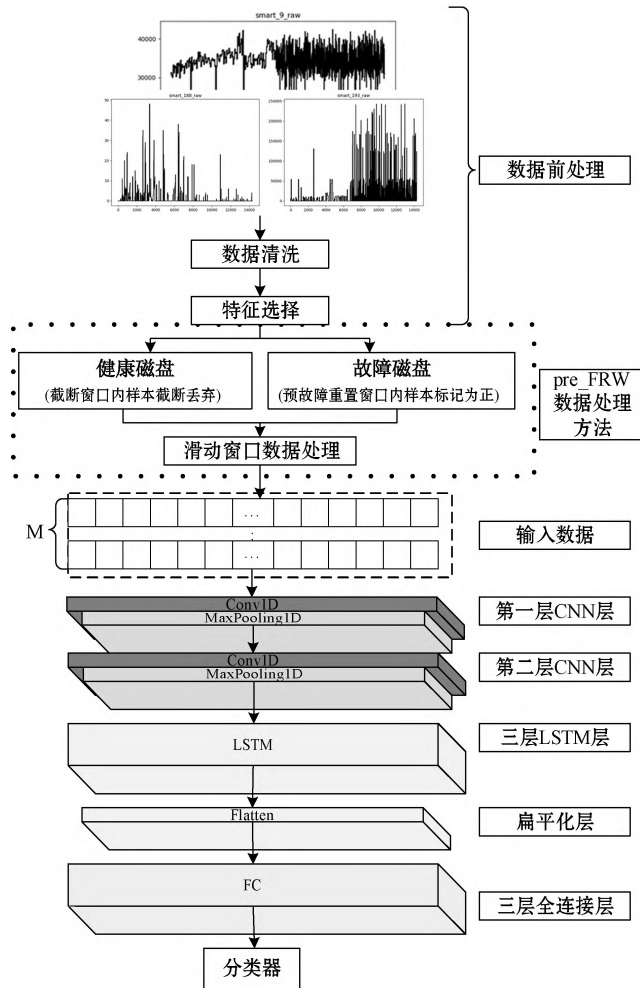


图1 基于 pre_FRW-CNN-LSTM 的磁盘故障预测模型结构

2.2 数据清洗与特征选择

SMART 技术统计磁盘固件随时间变化的监测数据,覆盖所有磁盘与错误相关或状态相关的属性。每个 SMART 数据条目都是一个键-值对,其中键是磁盘 ID,值是各种描述磁盘工作状态的属性值列表。这些磁盘在一年时间就会覆盖将近四千万条 SMART 数据,所以有效的数据前处理工作是磁盘故障预测有效性的保证。为了确保实验数据具有相同的分布特性,实验采用了来自希捷公司的型号为 ST4000DM000(以下简称数据集 ST4)的 SMART 数据,时间跨度为 2019 年 7 月到 12 月。

原始数据删除空值比例高于 20%、单值比例高于 90% 的属性,采取前向插值的方法进行缺失值填充。统计每个磁盘的工作天数,去除天数少于 30 天的磁盘,保证每个磁盘有足够实验使用的数据。

数据集 ST4 经过数据清洗后,得到了有 24 个属性的数据,属性值即代表特征值。选择合适的特征可以减少模型训练和预测的时间,而且提高预测的性能^[24]。特征选择的目的是去除不相关和冗余特征,选择相关的特征,减少数据量。本文使用基于信息增益比率的特征选择方法对数据集进行特征选择,信息增益比率是机器学习中经典算法决策树中的一种算法^[18]。

计算 SMART 数据集中各特征的信息增益比率,需要先计算信息熵。信息熵越高,代表数据不确定性越大,则包含信息量就越多。数据集 ST4 用符号 X 代替,假设数据的取值有 K 类,那么每个类别的概率是 $|N_K|/|X|$,其中 $|N_K|$ 代表类别 K 的样本个数, $|X|$ 代表样本总数,则数据集 X 的信息熵 $H_{(X)}$ 的计算如式 (1) 所示:

$$H_{(X)} = - \sum_{k=1}^K \frac{|N_K|}{|X|} \log_2 \frac{|N_K|}{|X|} \quad (1)$$

假设按照特征 A 对 SMART 数据集 X 进行划分,若磁盘特征 A 有 n 个取值,则特征 A 的信息熵 $H_{A(X)}$ 的计算如式 (2) 所示。

$$H_{A(X)} = \sum_{i=1}^n \frac{|X_i|}{|X|} H_{(X_i)} \quad (2)$$

为了更详细地表示 SMART 数据集 X 中某个特征包含的信息量,将数据集某个特征的某个时刻前后信息熵的差值,定义为信息增益,那么信息增益 $IG_{(A)}$ 的计算如式 (3) 所示。

$$IG_{(A)} = H_{(X)} - H_{A(X)} \quad (3)$$

信息增益对磁盘数据集中取值较多的特征有偏好。比如当特征 A 的取值比较多时,那么特征 A 的子集信息熵就低,特征 A 的信息增益就会很大。因此,引用信息增益比率来避免这种情况。信息增益比率实际是在信息增益基础上增加一个惩罚参数。参数值的大小与特征的取值数为反比,信息增益和惩罚参数的乘积即为信息增益比率。惩罚参数 $PI_{A(X)}$ 和信息增益比率 $IGR_{(A)}$ 的计算如式 (4) - 式 (5) 所示。

$$PI_{A(X)} = - \frac{1}{\sum_{i=1}^n \frac{|X_i|}{|X|} \log_2 \left(\frac{|X_i|}{|X|} \right)} \quad (4)$$

$$IGR_{(A)} = \frac{IG_{(A)}}{PI_{A(X)}} \quad (5)$$

使用式 (5) 计算数据集 ST4 的 SMART 数据样本集合中每个特征的信息增益比率并降序排列,本文选

取了信息增益比率排名前 10 的特征作为磁盘故障预测模型中使用的特征,选择的 10 个特征信息如表 1 所示。

表 1 数据集 ST4 各特征信息增益比率

ID	特征含义	信息增益比率
5	Reallocated Sector Count	0.038 9
197	Uncorrectable Sector Count	0.037 6
194	Temperature	0.032 1
193	Load Cycle Count	0.030 6
188	Command Timeout	0.029 8
198	Uncorrectable Sector Count	0.028 3
187	Reported Uncorrectable Errors	0.022 7
9	Power-On Hours	0.021 0
1	Read Error Rate	0.017 7
7	Seek Error Rate	0.012 2

“ID”列代表选择的特征在原始数据集中的序号,“特征含义”列表示磁盘厂商定义 ID 对应的磁盘属性含义,比如 SMART_5 表示重定位扇区的数目,它获得了最高的信息增益比率。

同时,本文统计一些磁盘特征潜在的分布规律。数据集 ST4 中 191 个故障样本的 SMART_9 即磁盘通电时间的数据统计分布如图 2 所示。通电时间小于 1 200 天的磁盘极少发生故障,随着通电时间增加,磁盘故障个数也在增加,在 1 200 ~ 1 500 天内通电时间与故障个数大致满足正向关系。由于大于 1500 天的磁盘总数较少,所以故障个数减少,但同时时间段的故障比例依然在增加。以上表明,当磁盘的 SMART_9 特征值大于 1 200 天时,磁盘发生故障的可能性增大。




图 2 故障样本 SMART_9 属性的数据统计

本文还统计出磁盘的多个特征值大于 0 时,磁盘是否会发生故障比例,如表 2 所示。当组合特征中一

个或多个特征值大于 0 时,磁盘有很高的故障发生率,而健康磁盘的这五个特征值大于 0 的比例就很低,比如故障磁盘 SMART_198 的特征值大于 0 的比例比健康磁盘此特征值大于 0 的比例增加 100 多倍。

表 2 SMART 属性组合值大于 0 时磁盘健康/故障概率(%)

ID	5	187	188	197	198	综合
健康磁盘	1.1	0.5	4.8	0.7	0.3	4.2
故障磁盘	42.2	43.5	44.8	43.1	33.0	76.7

通过以上的统计分析,表明这些 SMART 属性与磁盘状态有较高的相关性,属性值的变化反映出磁盘状态的变化,也证明采用信息增益比率方法选择出来的特征具有合理性。

2.3 pre_FRW 数据处理

Backblaze 磁盘数据是将磁盘最终发生故障的当天标记为正样本,之前的样本标记为负样本,发生故障的磁盘就被更换,无后续数据。这种标记方法并不能准确地表示磁盘的状态,磁盘往往在最终故障之前就已经具备将要故障的特性,为了准确地反映磁盘的失效特性,将故障磁盘样本时刻前一定窗口内的样本也标记为正样本。同时选取的健康磁盘最后一天的样本可能就要发生故障,为了保证选取的健康磁盘样本不会存在将要故障的样本,对健康磁盘样本最后使用时刻前一定窗口内的样本进行截断丢弃。这种数据处理方法本文称之为预故障重置窗口(pre_FRW)的数据处理方法。

图 3 显示了本文的故障磁盘预故障重置窗口的设计,设 T_0 到 T_Y 是一个故障磁盘在使用时间段的运行时间, T_Y 时刻的样本是故障磁盘最后一天的样本,即正样本(黑色表示),预故障重置窗口 N 内的样本重置标记为正样本(灰色表示),表明样本将要发生故障,早期的样本为负样本(白色表示)。




图 3 故障磁盘预故障重置窗口(pre_FRW)的设计

如果只针对故障磁盘做预故障重置窗口处理,健康磁盘不做处理,那么就会存在一个潜在的问题。Backblaze 数据集只有当磁盘发生故障无法工作时,才会将磁盘标记为“1”。然而在本文选取的时间段内,可能存在选取的磁盘在时间段最后一天是健康标记的,但是在下一个工作日立即失效。按照本文的思想,

这些样本现在被“错误标记”为负样本,图4说明了这一问题。如果磁盘在 T_{Y+1} 时刻发生故障,那么本文应该将其重置窗口 N (T_{Y-N} 到 T_Y) 内的所有样本标记为正样本。但是,在本文使用的时间段内,不知道 T_{Y+1} 时刻的状态,所以对于健康标记的磁盘,重置窗口中的样本实际上是不明确的样本,因为它们可能在下一时刻就失效了。对于这样的样本,本文称之为模糊样本(问号表示)。在后续使用中,模糊样本会被截断丢弃,以保证健康样本的一致性。健康磁盘的预故障重置窗口的样本并不一定是故障样本,为了和故障磁盘的预故障重置窗口区分,健康磁盘的窗口又称为截断窗口(Cutting Window, CW),健康磁盘截断窗口长度等于故障磁盘的预故障重置窗口长度 N 。



图4 健康磁盘截断窗口(CW)的设计

为了方便数据输入模型结构,本文对时序数据做了滑动窗口的处理,处理过程如图5所示。从每个磁盘最后时刻的数据选取窗口大小为 S 的样本,并向前做 L 次滑动。将选取的样本输入模型结构中,预测最后一个数据。




图5 故障磁盘滑动窗口示意图

本文提出的完整 pre_FRW 数据处理方案工作原理如下:如果磁盘在 T_Y 时刻是健康标记的,本文将其在截断窗口内的所有样本(T_{Y-N} 到 T_Y) 丢弃,并将截断窗口外的任何样本标记为负样本。否则,如果磁盘在时刻 T_Y 出现故障,本文把重置窗口内的所有样本(T_{Y-N} 到 T_Y) 标记为正,并将重置窗口外的其余样本标记为负样本。同时对重新标记处理后的数据做滑动窗口选择,为模型数据输入做好基础。

2.4 CNN-LSTM 的模型结构

本文故障预测模型是 LSTM 在磁盘故障预测领域取得良好效果的基础上,借鉴文献[22]中 CNN 在一维时间序列网页流量数据集上取得的最佳性能结构,提

出 CNN-LSTM 组合神经网络对磁盘多维监控数据进行磁盘故障预测。CNN 层提取数据的空间特征,LSTM 层有效捕捉时间序列之间的依赖关系,利用前向全连接神经网络组成的全连接层(FC)对提取的特征进行分类训练,并预测下一时刻的值实现故障预测。

CNN-LSTM 结构如图1所示。首先,CNN 结构由两层 1D 卷积层、两层最大池化层和利用 ReLU 函数作为激活函数组成。卷积层可以提取数据高层空间特征,但相邻卷积核提取的信息相似且冗余。因此,在保持空间信息的同时,采用最大池化层进行下采样。前池化层的输出到三层 LSTM 层,获取磁盘时序数据的依赖关系。经过扁平化层后,传入到三层完全连接层,用 Softmax 分类器检测出异常。其中 L 设置为 60,则通过第一层卷积层之后数据的大小为 $60 \times 128 \times 10$,卷积层利用零填充来保持特征的数量,但最大池化层不使用任何填充。来自最大池化层的下采样数据的大小为 $60 \times 128 \times 5$ 。然后,将数据输入到第二层卷积层中,并且输出的大小为 $60 \times 64 \times 5$ 。在第二个最大池化层中进行下采样后,输出的大小为 $60 \times 64 \times 2$ 。数据输入到 LSTM 之前,数据被平坦为 60×128 。而 LSTM 结构的单元数也设置为 128,最终输入完全连接层的数据大小为 1×128 ,供分类器检测异常。

pre_FRW 处理后的 SMART 磁盘数据描述:设有时序数据集 $X = \{(X_1, Y_1), (X_2, Y_2), \dots, (X_M, Y_M)\}$,包含 M 个样本。每个样本 $X_i \in \mathbf{R}^{S \times D}$ 是一个时序数据样本, S 表示样本序列的长度, D 表示样本特征选取后的维度。 $Y_i \in (0, 1)^{S \times 1}$ 表示时序数据样本 X_i 中 S 个时刻的标签。0 代表负样本,1 代表正样本。

假设磁盘时序数据集 X 的一个样本由 S 个数据组成 $x = (x_1, x_2, \dots, x_S)$, $x \in (X_1, X_2, \dots, X_M)$, S 为滑动窗口的长度值。由于数据集是多维数据,为了方便公式推导展示,以下公式表示以一个特征为例,其他特征的处理方式等同。若 x_i 是标准化后的值, i 是特征值的索引, j 是每个窗口特征映射的下标。第一个卷积层输出 y_{ij}^1 由式(6)表示。

$$y_{ij}^1 = \sigma(b_j^0 + \sum_{f=1}^F W_{fj}^0 x_{i+f-1}^0) \quad (6)$$

y_{ij}^1 是由输入数据中 x_{ij}^0 计算的, b_j^0 表示第 j 个特征映射的偏差, W 是卷积核的权重, F 是滤波器的数量, σ 表示激活函数,本文使用 ReLU 函数。当有多个卷积层时,第 l 个卷积层输出值 y_{ij}^l 由式(7)表示。

$$y_{ij}^l = \sigma(b_j^{l-1} + \sum_{f=1}^F W_{fj}^{l-1} x_{i+f-1}^{l-1}) \quad (7)$$

卷积层之后有最大池化层。池化层可以减少表示

的空间大小,有降低网络的参数数量和计算复杂度的效果,同时一定程度上还能防止过拟合。池化层通过对每个深度切片独立应用最大操作来有效地减少空间大小。池化层的操作由式(8)表示。

$$p_{ij}^l = \max_{r \in R} y_{i \times st + r, j}^{l-1} \quad (8)$$

R 是池化大小, st 是池化区域移动的步长。最大池化是选择子区域中最大数目池的一种类型,在子区域中选择最大值是有效的,因为它表示当特征存在时进行了大量的激活。最大池化比平均池化或者 L2 范数池化有更好的性能表现。

在 LSTM 层中,池化层的输出作为输入,并应用门控的概念。门控是一种基于乘法的机制,其中输入的一个组件定义了每个存储单元的行为。每个 LSTM 单元根据每个门的激活更新其单元状态,并由 0 到 1 之间的连续值控制。提供给 LSTM 的输入,实际上是被输入到控制输入、输出和遗忘门的操作中,这些门控是在内存单元管理的。 h_t 是 LSTM 单元的隐藏值,每个时间步 t 会更新它的值。

$$i_t = \sigma(w_{pi}p_t + w_{hi}h_{t-1} + w_{ci} \circ c_{t-1} + b_i) \quad (9)$$

$$f_t = \sigma(w_{pf}p_t + w_{hf}h_{t-1} + w_{cf} \circ c_{t-1} + b_f) \quad (10)$$

$$o_t = \sigma(w_{po}p_t + w_{ho}h_{t-1} + w_{co} \circ c_{t-1} + b_o) \quad (11)$$

$$c_t = f_t \circ c_{t-1} + i_t \circ (w_{pc}p_t + w_{hc}h_{t-1} + b_c) \quad (12)$$

$$h_t = o_t \circ \sigma(c_t) \quad (13)$$

式中: i 、 f 和 o 分别表示输入、忘记和输出门。 c 和 h 分别表示单元状态和隐藏层的值,它们的值由三种类型门的输出决定的。 σ 同 CNN 层表示含义一样为激活函数,不同的是 LSTM 层中的激活函数采用 sigmoid 和 tanh 函数。 p_t 是池化层在时间步 t 时的输出,作为内存单元层的输入。 w 是权重矩阵, b 是偏置向量, \circ 表示 Hadamard 乘积。使用 LSTM 单元的网络在捕捉时间序列之间的依赖关系时有很好的效果,这给磁盘时序数据的故障预测提供了基础^[24]。

完全连接层和 Softmax 分类器的组合可以用来检测故障磁盘中的异常。将 LSTM 单元的输出扁平化为特征向量 $h^l = (h_1, h_2, \dots, h_n)$, n 是 LSTM 最后一层的单元数。此向量用作完全连接层的输入,该层涉及的计算公式如式(14)表示。

$$d_i^l = \sum_j \sigma[w_{ji}^{l-1}(h_j^{l-1}) + b_i^{l-1}] \quad (14)$$

式中: σ 表示激活函数, w_{ji}^{l-1} 表示 $l-1$ 层的第 i 个节点和 l 个节点的权重, b_i^{l-1} 表示偏差,而 d 代表完全连接层的输出,输出值被 Softmax 分类为 0 或 1,分别代表着健康或故障磁盘。以上就是完整的 CNN-LSTM 故障预测模型的公式推导。

3 实验与结果分析

3.1 数据集

实验数据集来自云存储服务提供商 Backblaze 云数据中心采集的数据,采集频率为一天一次,包含 2013 年 4 月到现在所有使用磁盘的 SMART 信息^[25]。每条 SMART 数据包含多个有实际记录数值的属性值,每个属性值由原始属性值和标准化属性值组成。标准化规则是由磁盘厂商自己定义的准则,每家厂商的准则不同且无从得知。为了保证实验模型对数据的敏感性,所以实验只使用原始属性值,本文对原始属性值进行标准差标准化,使得经过处理的数据符合标准正态分布,如式(15)所示。

$$x^* = \frac{x - \mu}{\sigma} \quad (15)$$

本文选取后的 ST4 数据集具有最高的故障发生率 1%,包含 19 706 块健康磁盘、191 块故障磁盘,是目前保有量最高的磁盘型号。

原始数据经过 pre_FRW 的数据处理,并采用滑动窗口的设计。预故障重置窗口 N 和滑动窗口 S 的大小将在实验中探索,因为窗口大小的设置会影响模型的性能。磁盘时序数据的训练集和测试集按照磁盘个数 8:2 比例分割,即 80% 的磁盘用来训练,剩下 20% 的磁盘用作测试。而不是按照时间顺序分割,一是因为磁盘发生故障后就无后续数据,二是可以验证模型的泛化能力。最终选择 440 个磁盘共 29 800 个样本用作训练集,110 个磁盘共 7 500 个样本用作测试集。

3.2 评价指标

介绍评价指标之前,需要清楚故障预测的定义:每个磁盘的时序数据设置 L 个滑动窗口,滑动窗口 S 内的数据作为一个样本,每个样本最后时刻的值作为要预测的值,窗口 N 又作为提前预测的天数。这样满足当故障磁盘的预故障重置窗口内有被预测为故障的样本时,就表明磁盘在未来的 N 天内会发生故障。

本文使用故障检测率(Failure Detection Rate, FDR)和错误告警率(False Alarm Rate, FAR)两种指标,它们被广泛用于评估磁盘故障预测的有效性^[26-27]。FDR 是指正确预测的故障磁盘占全部故障磁盘数的比率, FAR 是指将健康磁盘预测错误占全部健康磁盘数的比例。FDR 和 FAR 的计算如式(16) - 式(17)所示。

$$F_{DR} = \frac{T_p}{T_p + F_n} \times 100\% \quad (16)$$

$$F_{AR} = \frac{F_p}{F_p + T_n} \times 100\% \quad (17)$$

式中: T_p 表示故障磁盘被正确预测的数目; T_N 表示健康磁盘被正确预测的数目; F_N 表示故障磁盘被错误预测的数目(又称为漏报数); F_p 表示健康磁盘被错误预测的数目(又称为误报数)。

3.3 实验设置

本文实验所在系统环境为 Windows 10, 处理器型号为 Intel(R) Core(TM) i7-8700 CPU @ 3.20 GHz, 内存 16 GB, 显卡型号为 NVIDIA GeForce GTX 1050, 显存为 4 GB。实验开发语言版本为 Python 3.6, 使用的深度学习框架为 TensorFlow-GPU。

在训练 CNN 和 LSTM 之前, 需要设置一些超参数。在本文 CNN-LSTM 结构中, 第一层 CNN 的滤波器数量为 128, 需要使用大小为 5 的核来最小化信息损失, 零填充用于卷积操作, 激活函数选择 ReLU 函数, 后跟最大池化层。第二层 CNN 滤波器数量为 64, 其他保持一致。三层 LSTM 的最佳单元数设置为 128, dropout 为 0.2, 同时添加 Batch Normalization 层, 具有正则化的效果, 提高模型的泛化能力。优化器使用 Adam, 初始学习率设置为 0.001, epoch 根据实验最佳结果设置为 400, 损失函数采用二进制交叉熵, 测试结果取 10 次实验平均值。

3.4 实验结果分析

在第 2 节中, 详细描述了本文提出的故障磁盘预故障重置窗口(pre_FRW)和健康磁盘截断窗口(CW)的数据处理方法, 未采取此数据处理的 basic 方法是只将故障当天的数据作为正样本, 其他时刻样本作为负样本, 其他处理方法一致。

为了验证本文的 pre_FRW 数据处理有效性, 比较在不同滑动窗口和不同预故障重置窗口下, 本文提出的数据处理方法的 FDR 以及 FAR 的变化情况, 所有对比实验选择本文使用的 CNN-LSTM 深度学习模型。

如图 6 所示, 采用 pre_FRW 数据处理方法始终比 basic 方法的 FDR 高 7.5% ~ 10% 左右, 在 pre_FRW 基础上又使用 CW 补充数据处理的方法, 又进一步提升约 2% 的 FDR。结果表明基于故障磁盘 pre_FRW 数据处理的方法对故障前样本重置标签为正样本, 能够更加准确描述故障磁盘的特性, 提高模型的预测效果。同时基于健康磁盘 CW 数据处理的结果表明, 使用的健康磁盘时序数据在最后时刻的下一时刻存在立即故障的特殊情况。将这样的数据截断丢弃, 减少模糊样本对模型的干扰, 也能一定程度提升性能表现。随着滑动窗口的增加, FDR 逐步提升, 在 8 ~ 10 天达到最高, 之后开始下降, 在这里选择滑动窗口为 9 作为最

佳值。




图6 pre_FRW 方法的 FDR 随滑动窗口 S 变化趋势

如图 7 所示, 随着预故障重置窗口 N 的增加, FDR 增加明显, 在 $N=6$ 时, FDR 趋向于平稳, 但后续处于波动上升的趋势。而 FAR 一开始缓慢提升, 当 $N=10$ 时, FAR 迅速提高。这是因为当 N 一直增大时, 会出现将符合健康磁盘特性的负样本错误重置为正样本, 分类结果会降低, 但由磁盘故障预测的定义, N 也作为提前预测的天数, 在窗口 N 内依然能够预测到真正的正样本, 所以 FDR 是波动上升的趋势。而 FAR 随着 N 的增大, pre_FRW 数据处理方法将负样本错误重置为正样本的数据较多, 那么预测模型会将更多的健康磁盘真实负样本预测成错误的正样本, 即 FP 增大, 同时 TN 降低, 所以 FAR 指标呈现迅速增长的趋势。为了平衡这两个指标, 本文选取预故障重置窗口 N 为 7, 此时的 FDR 为 91.47%, FAR 为 0.15%。




图7 pre_FRW 方法的 FDR、FAR 随预故障窗口 N 变化趋势

为了验证本文提出的 pre_FRW-CNN-LSTM 磁盘故障预测方法的有效性, 使用数据集 ST4 对几种常用的磁盘故障模型进行建模训练, 并测试了各模型的预测性能。实验选择支持向量机(SVM)^[7]、分类与回归树

(CART)^[8]、符号化数据处理方式的 LSTM 结构(Sym. + LSTM)^[17]、特征值健康度表示的 LSTM 结构(HD + LSTM)^[18]、LSTM 加上全连接层的结构(LSTM-FC)^[19]作为本文基线模型。同时对比 pre_FRW 数据处理的单一 CNN 和 LSTM 模型。

使用 FDR 和 FAR 作为模型的主要对比指标,FDR 越高代表预测出未来发生故障的概率越大,FAR 越低代表预测出故障的错误告警概率越小,是高性能的表现。除了 FDR、FAR 评价指标之外,在磁盘故障预测领域常会使用故障预测提前时间(Leading Time ,LT)作为评价模型优越性的一个性能评估指标。LT 是指预测模型在磁盘故障真实发生时最早提前多少时间预测即将发生的故障,而 LT 的长短意味着云数据中心是否可以在发生故障警报到故障真实发生时间之内将数据进行备份或迁移。本文统计各预测模型预测成功的每个磁盘的 LT 值分布。例如,pre_FRW + CNN-LSTM 预测模型的 FDR 为 93.72%,故障磁盘总数为 191 个,则两者相乘就是预测成功磁盘数即 179 个。为方便绘图,pre_FRW 方法简写成 FRW。分布图形如图 8 所示。




图 8 数据集 ST4 各预测模型的预测提前时间 LT

可以看出,SVM 预测模型的预测提前时间总体最短,只接近 4 天。pre_FRW + CNN-LSTM 预测模型提前时间大于 15 天的磁盘占比有 15.4%,而排名第二位的预测模型 HD + LSTM 只有 5.1%。为了量化各预测模型的预测提前时间指标的总体性能,引入预测平均提前时间(Mean Leading Time ,MLT)的概念,即每个预测成功的故障磁盘的平均 LT 值,图 8 中黑色圆点代表各预测模型的 MLT 值,可以看出本文提出的预测模型 pre_FRW + CNN-LSTM 具有最长的 MLT 值。基于数据集 ST4 的各预测模型的评价指标结果如表 3 所示。

表 3 ST4 数据集的各模型实验结果

模型	FDR/%	FAR/%	MLT/天
SVM	67.24	1.24	4
CART	80.80	0.19	5
Sym. + LSTM	88.52	0.90	6
HD + LSTM	91.80	0.18	10
LSTM-FC	86.45	0.56	8
pre_FRW + CNN	83.10	0.75	7
pre_FRW + LSTM	89.66	0.31	9
pre_FRW + CNN-LSTM(a)	93.72	0.48	12
pre_FRW + CNN-LSTM(b)	91.47	0.15	12

可以看出 SVM 的性能较差,SVM 寻找一个可以包裹负样本的超平面作为决策面,但由于磁盘数据集是多维数据,难以有一个合适的超平面。CART 对时序数据要求很高的数据处理,本文获取到的最好性能与其他模型依然存在差距。LSTM 作为主要结构的各个模型能够得到好的预测效果,说明 LSTM 对时序数据的依赖关系能有效捕捉。LSTM-FC 是做无监督的故障预测,在复杂的磁盘数据集上不够理想。Sym. + LSTM 和 HD + LSTM 的数据处理思想相似,都是将原始数据转换成另外一种表示方式,简化数据的分布变化,但都依赖聚类结果的准确性,不准确的聚类会降低 FDR。

基于 pre_FRW 数据处理的单一 CNN 和 LSTM 模型结构的性能表现是不如 CNN-LSTM 的组合模型结构,LSTM 比 CNN 获得更高的 FDR 进一步说明 LSTM 在磁盘时序数据上的优势。CNN-LSTM 模型结构在滑动窗口 S 取 9,预故障重置窗口 N 取 7 的时候,对比基线获得了最好的效果。其中条件(a) 是 FDR 达到最高 93.72% 时,对应的 FAR 不如 HD + LSTM; 条件(b) 是 FAR 取得最低 0.15% 时,对应的 FDR 会比 HD-LSTM 低,但总体相差不大。在实际云数据中心运维过程中,允许存在一定的错误告警率(FAR),优先保证高的故障预测率(FDR),保护存储数据的安全,维护存储系统稳定,降低服务企业的数据缺失导致的经济损失。所以 pre_FRW-CNN-LSTM 的磁盘故障预测方法相对于 HD + LSTM 有更好的性能表现,在基线模型结构对比中得到了最佳的性能,能够比其他预测模型更早地发现磁盘将要发生故障且预测出更多的故障磁盘。

综合以上实验结果可以表明,本文提出的 pre_FRW-CNN-LSTM 磁盘故障预测方法,对磁盘多维时间序列合理的特征选择,对 SMART 数据集更加准确地标记解决数据集不平衡问题,采取的 CNN-LSTM 组合模型对比基线提升 2% ~ 10% 的故障预测率,平均预测提前时间得到最高值,同时错误告警率保持较低水平。

4 结 语

针对磁盘故障预测问题存在的样本不平衡、标签不准确问题,本文基于故障磁盘预故障重置窗口、健康磁盘截断窗口的数据处理方法,设计了一种卷积神经网络和长短期记忆网络结合的故障预测模型结构。与其他方法相比,本文的磁盘故障预测方法能正确标记数据样本,丢弃模糊数据样本,对数据做有效地处理,同时神经网络能有效提取磁盘时序数据的时空特征,提高预测效果。通过在 Backblaze 云数据中心数据与其他方法的对比实验,故障预测率提升了 2% ~ 10%,有更早的预测时间,且错误告警率保持低水平,验证本文方法的有效性。后续工作中,在数据处理和网络结构方面进一步探索,以获得更高的故障预测率。

参 考 文 献

- [1] Botezatu M, Giurgiu I, Bogojeska J, et al. Predicting disk replacement towards reliable data centers [C]//22nd ACM SIGKDD International Conference on Knowledge Discovery & Data Mining 2016: 39–48.
- [2] Vishwanath K V, Nagappan N. Characterizing cloud computing hardware reliability [C]//1st ACM Symposium on Cloud Computing 2010: 193–204.
- [3] Wang Y, Miao Q, Ma E W, et al. Online anomaly detection for hard disk drives based on Mahalanobis distance [J]. IEEE Transactions on Reliability 2013 62(1): 136–145.
- [4] Murray J F, Hughes G F, Kreutz-Delgado K. Machine learning methods for predicting failures in hard drives: A multiple-instance application [J]. Journal of Machine Learning Research 2015 16(1): 783–816.
- [5] Hughes G F, Murray J F, Kreutz-Delgado K, et al. Improved disk-drive failure warnings [J]. IEEE Transactions on Reliability 2012 61(3): 350–357.
- [6] Ma A, Douglas F, Lu G L, et al. RAIDShield: Characterizing, monitoring, and proactively protecting against disk failures [C]//13th USENIX Conference on File and Storage Technologies 2015: 241–256.
- [7] Aussel N, Jaulin S, Gandon G, et al. Predictive models of hard drive failures based on operational data [C]//IEEE International Conference on Machine Learning & Applications, 2017: 619–625.
- [8] Li J, Ji X P, Jia Y H, et al. Hard drive failure prediction using classification and regression trees [C]//44th Annual IEEE/IFIP International Conference on Dependable Systems and Networks 2014: 383–394.
- [9] Zhu B P, Wang G, Liu X G, et al. Proactive drive failure prediction for large scale storage systems [C]//29th Symposium on Mass Storage Systems and Technologies 2013: 1–5.
- [10] Shen J, Wan J, Lim S J, et al. Random-forest-based failure prediction for hard disk drives [J]. International Journal of Distributed Sensor Networks 2018 14(11): 480–491.
- [11] Botezatu M, Giurgiu I, Bogojeska J, et al. Predicting disk replacement towards reliable data centers [C]//22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining 2016: 39–48.
- [12] Jiang T M, Huang P, Zhou K. Scrub Unleveling: Achieving high data reliability at low scrubbing cost [C]//Design, Automation & Test in Europe Conference & Exhibition 2019: 1403–1408.
- [13] Bairavasundaram L N, Goodson G R, Pasupathy S, et al. An analysis of latent sector errors in disk drives [C]//ACM SIGMETRICS International Conference on Measurement and Modeling of Computer Systems 2017: 289–300.
- [14] Gunawi H S, Suminto R O, Sears R, et al. Fail-slow at scale: Evidence of hardware performance faults in large production systems [C]//ACM Transactions on Storage 2018, 14(3): 1–26.
- [15] Xiao J, Xiong Z, Wu S, et al. Disk failure prediction in data centers via online learning [C]//47th International Conference on Parallel Processing 2018: 1–10.
- [16] Xu Y, Sui K X, Yao R, et al. Improving service availability of cloud systems by predicting disk error [C]//USENIX Conference on USENIX Annual Technical Conference 2018: 481–494.
- [17] Zhang S D, Bahrapour S, Ramakrishnan N, et al. Deep learning on symbolic representations for large-scale heterogeneous time-series event prediction [C]//IEEE International Conference on Acoustics 2017: 5970–5974.
- [18] 康艳龙. 基于深度学习的硬盘故障预测技术研究 [D]. 西安: 西安电子科技大学 2019.
- [19] 姜少彬, 杜春, 陈浩, 等. 一种硬盘故障预测的非监督对抗学习方法 [J]. 西安电子科技大学学报(自然科学版), 2020 47(2): 118–125.
- [20] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks [J]. Communications of the ACM 2017 60(6): 84–90.
- [21] Wang W, Zhu M, Wang J L, et al. End-to-end encrypted traffic classification with one-dimensional convolution neural networks [C]//IEEE International Conference on Intelligence and Security Informatics 2017: 43–48.
- [22] Liu C L, Hsiao W H, Tu Y C. Time series classification with multivariate convolutional neural network [J]. IEEE Transactions on Industrial Electronics 2018 66(6): 4788–4797.

(下转第 149 页)

算法,以进一步提高传输效率。即,当网络带宽较低时,采用具有良好压缩比的慢压缩方法,当网络带宽较高时,采用快压缩方法。

参 考 文 献

- [1] Clark T. PACS and imaging informatics: Basic principles and applications[J]. Biomedical Instrumentation & Technology 2006 40(2): 125-125.
- [2] 田捷,白净,包尚联. 医学影像处理与分析专刊前言[J]. 软件学报 2009 20(5): 1087-1088.
- [3] Teng D J, Kong J, Wang F S. Scalable and flexible management of medical image big data[J]. Distributed and Parallel Databases 2019 37(2): 235-250.
- [4] 黄姗. 基于IHE技术框架的医疗信息系统研究及设计实现[D]. 西安: 西安电子科技大学 2015.
- [5] 王立功,刘伟强,于甬华,等. DICOM医学图像文件格式解析与应用研究[J]. 计算机工程与应用 2006(29): 210-212 225.
- [6] Boussif M, Aloui N, Cherif A. DICOM imaging watermarking for hiding medical reports[J]. Medical & Biological Engineering & Computing 2020 58: 2905-2918.
- [7] Yuan J T, Zhang W Q, Wu W, et al. Desensitization and cleaning technology of CT image of parotid tumor based on DICOM[J]. Journal of Physics: Conference Series, IOP Publishing 2020 1576: 24-26.
- [8] 于大宇,唐丽玉,李海波,等. 基于DICOM的多平台放射治疗数据可视化与对比分析[J]. 中国医学物理学杂志, 2019 36(5): 517-524.
- [9] Kulkarni R. Analysis of CT DICOM image segmentation for abnormality detection[J]. International Journal of Engineering and Manufacturing 2019 9: 46-55.
- [10] Drnasin I, Grgic M, Gledec G. Exploring WebRTC potential for DICOM file sharing[J]. Journal of Digital Imaging 2019, 33: 697-707.
- [11] Lim H S, Yoon W, Chung T W, et al. FDG PET/CT for the detection and evaluation of breast diseases: Usefulness and limitations [J]. RadioGraphics: Radiological Society of North America 2007 27(S1): 197-213.
- [12] Kapoor V, McCoock B M, Torok F S. An introduction to PET-CT imaging [J]. RadioGraphics: Radiological Society of North America 2004 24(2): 523-543.
- [13] 危育冰. 基于八叉树编码的散乱点云数据压缩[J]. 武汉大学学报(工学版) 2020 53(8): 734-739.
- [14] 兰渐霞,王泽勇,李金龙,等. 基于非均匀划分的机车走行部三维点云精简[J]. 光电工程 2019 46(2): 28-36.
- [15] 李斌,李德来,张琼. 基于Bandlet的压缩感知算法及其在智能乳腺全容积超声系统中的应用[J]. 北京生物医学工程 2017 36(4): 343-347.
- [16] 朱新山,杨璐. 基于H.264与新一代视频编码标准的压缩域视频水印综述[J]. 信息安全学报 2018 3(6): 28-41.
- [17] Maitre A, Fernando J, Morvan Y, et al. Comparative performance investigation of DICOM C-STORE and DICOM HT-TP-based requests [C]//36th Annual International Conference of the IEEE Engineering in Medicine and Biology Society 2014: 1350-1353.
- [18] Veeramani S, Masood M N, Sidhu A S. A PACS alternative for transmitting DICOM images in a high latency environment [C]//IEEE Conference on Biomedical Engineering and Sciences 2014: 975-978.
- [19] Liu L J, Liu L, Fu X D, et al. SmartWADO: An extensible WADO middleware for regional medical image sharing [J]. Journal of Digital Imaging 2015 28(5): 547-557.
- [20] Drnasin I, Grgic M, Gledec G. Exploring WebRTC potential for DICOM file sharing[J]. Journal of Digital Imaging 2020, 33(3): 697-707.
- [21] 杜振伟,王之,霍达,等. 瓦片式算法在家庭网络环境实现高分辨率医学影像实时浏览与传输的研究[J]. 中国数字医学 2012 7(12): 54-57.
- [22] 蔡荣杰,郭文明. 基于对等网络的DICOM传输模式研究[J]. 中国医疗设备 2008(4): 6-8.
- [23] 刘伟,赵辉. 医学影像多尺度压缩传输方法的研究[J]. 计算机工程与应用 2007 43(17): 213-215.
- [24] Rodrigues V F, Paim E P, Kunst R, et al. Exploring publish/subscribe, multilevel cloud elasticity, and data compression in telemedicine [J]. Computer Methods and Programs in Biomedicine 2020 191: 105403.
- [25] Hsu W Y. Clustering-based compression connected to cloud databases in telemedicine and long-term care applications [J]. Telematics and Informatics 2017 34(1): 299-310.

(上接第100页)

- [23] Murray J F, Hughes G F, Kreutz-Delgado K. Machine learning methods for predicting failures in hard drives: A multiple-instance application[J]. Journal of Machine Learning Research 2015 16: 783-816.
- [24] Kim T Y, Cho S B. Web traffic anomaly detection using C-LSTM neural networks[J]. Expert Systems with Applications 2018 106: 66-76.
- [25] Backblaze. Hard drive data and stats[DS/OL]. [2020-12-24]. <https://www.backblaze.com/b2/hard-drive-test-data.html>.
- [26] Ordóñez F J, Roggen D. Deep convolutional and LSTM recurrent neural networks for multimodal wearable activity recognition[J]. Sensors 2016 16(1): 115.
- [27] Xiao J, Xiong Z, Wu S, et al. Disk failure prediction in data centers via online learning [C]//47th International Conference on Parallel Processing 2018: 1-10.