

陈万志,李昊哲,刘恒嘉,等.融合 LSTM 和优化 SVM 的风力发电机组故障预测方法[J].辽宁工程技术大学学报(自然科学版),2022,41(4):379-384. doi:10.11956/j.issn.1008-0562.2022.04.014

CHEN Wanzhi,LI Haozhe,LIU Hengjia,et al.Wind turbine fault prediction method based on LSTM and optimized SVM[J].Journal of Liaoning Technical University(Natural Science),2022,41(4):379-384.doi:10.11956/j.issn.1008-0562.2022.04.014

融合 LSTM 和优化 SVM 的风力发电机组故障预测方法

陈万志¹, 李昊哲², 刘恒嘉³, 王天元⁴

(1.辽宁工程技术大学 软件学院, 辽宁 葫芦岛 125105; 2.辽宁工程技术大学 电子与信息工程学院, 辽宁 葫芦岛 125105; 3.长春理工大学 计算机科学技术学院, 吉林 长春 130022; 4.国网辽宁省电力有限公司 营口供电公司, 辽宁 营口 115000)

摘 要: 针对风电机组基于 SCADA 数据预测分析故障效率低、准确度差的问题, 提出一种融合长短期记忆网络(LSTM)和麻雀搜索算法(SSA)优化支持向量机(SVM)的机器学习模型.首先, 利用 SCADA 历史数据分别训练 LSTM 和 SVM, 使其分别具有预测未来数据和判别故障状态的能力; 其次, 采用 SSA 优化 SVM, 保障其寻优能力强、收敛速度快; 最后, 通过优化的 SVM 对 LSTM 预测得到的未来数据进行故障状态识别判定, 实现风电机组短期故障预测.通过现场数据测试结果表明: 所提出的方法预测风电机组故障准确率为 97.90%, 能够满足现场对风电机组短期故障预测的实际需求.

关键词: 风力发电机组; SCADA; LSTM; SSA; SVM; 故障预测

中图分类号: TP 306+.3

文献标志码: A

文章编号: 1008-0562(2022)04-0379-06

Wind turbine fault prediction method based on LSTM and optimized SVM

CHEN Wanzhi¹, LI Haozhe², LIU Hengjia³, WANG Tianyuan⁴

(1.College of software, Liaoning Technical University, Huludao 125105, China; 2.School of Electronic and Information Engineering, Liaoning Technical University, Huludao 125105, China; 3.School of Computer Science and Technology, ChangChun University of Science and Technology, Changchun 130022; 4.State Grid Yingkou Electric Power Company, Liaoning Electric Power Supply Company Limited, Yingkou 115000, China)

Abstract: In response to the problems of low fault efficiency and poor accuracy in SCADA data prediction and analysis of wind turbines, a machine learning model combining LSTM and SSA to optimize SVM is proposed. Firstly, LSTM and SVM are trained with SCADA historical data to make them have the ability to predict future data and identify fault state respectively; secondly, SSA is used to optimize SVM to ensure its strong optimization ability and fast convergence speed; finally, the optimized SVM is used to identify fault state of LSTM predicted future data to realize short-term fault prediction of wind turbine. The field data test results show that the fault prediction accuracy of the proposed method is 97.90%, which can meet the actual needs of short-term fault prediction of wind turbines.

Key words: wind turbine; SCADA; LSTM; SSA; SVM; fault prediction

0 引言

风力发电机组的故障多源于发电机、齿轮箱、传动轴、叶片及变桨系统、偏航系统、电控系统等关键部件, 可通过检测分析振动、应力、扭矩、温

度、润滑油和电气等参数进行判别.风电场的 SCADA (supervisory control and data acquisition) 系统可实现对风电机组的监测监控功能.但基于 SCADA 数据的分析挖掘应用较少或仅用于人工统计, 无法预测风电机组故障可能发生的情况^[1-4].

收稿日期: 2021-03-16

基金项目: 国家重点研发计划项目(2018YFB1403303); 辽宁省教育厅科学研究面上项目(LJKZ0327); 辽宁工程技术大学双一流学科建设创新团队项目(LNTU20TD-25)

作者简介: 陈万志(1977-), 男, 辽宁 黑山人, 博士, 副教授, 主要从事人工智能与智能信息处理、工控软件与数据分析方面的研究.

由于对 SCADA 系统数据的分析已无法满足安全的需求, 研究者们将 SCADA 系统数据与机器学习模型结合, 对风电机组进行故障预测和诊断. 文献[5]提出结合 ITD (intrinsic time-scale decomposition) 和 LS-SVM (least square-support vector machine) 的风力发电机组轴承故障诊断方法. 文献[7]提出一种基于粒子群优化 KFCM (kernel fuzzy c-means clustering) 的风电齿轮箱故障诊断方法. 文献[8]提出一种基于小波包变换 BP (back propagation) 神经网络的齿轮箱故障诊断方法. 文献[9]提出一种基于小波包分析与 SVM 相结合的故障诊断新方法. 文献[10]提出一种基于隐半 Markov 模型的故障诊断和预测方法. 目前利用 SCADA 数据进行分析挖掘还存在精准度不高、实时效果差等问题.

本文以某风场 SCADA 系统数据为基础, 通过分析发电机温度、室外温度以及风速等参数, 在 SVM 模型的基础上融合 LSTM (long short-term

memory) 和 SSA (sparrow search algorithm) 优化 SVM 的方法实现风力发电机组短期故障预测.

1 整体框架

所提出风电机组故障预测模型的系统整体框架见图 1. 即通过同步风电机组 SCADA 系统小电机温度、液压温度、大电机 3 种温度、高速轴温度、齿轮油温度、风速以及室外温度等数据, 并对其进行数据预处理, 处理后的测试数据分别用于 LSTM 和 SSA 优化的 SVM 模型训练与测试; 其次利用优化后的 SVM 对 LSTM 的短期预测数据进行分类判定, 得到风电机组故障预测结果. 最终实现基于 SCADA 实时和历史数据的风电机组未来短期故障的预测, 为故障诊断与预测分析提供系统模型基础, 为保障风电机组的安全可靠运行、适时运维保养和故障危害最小化提供科学依据.

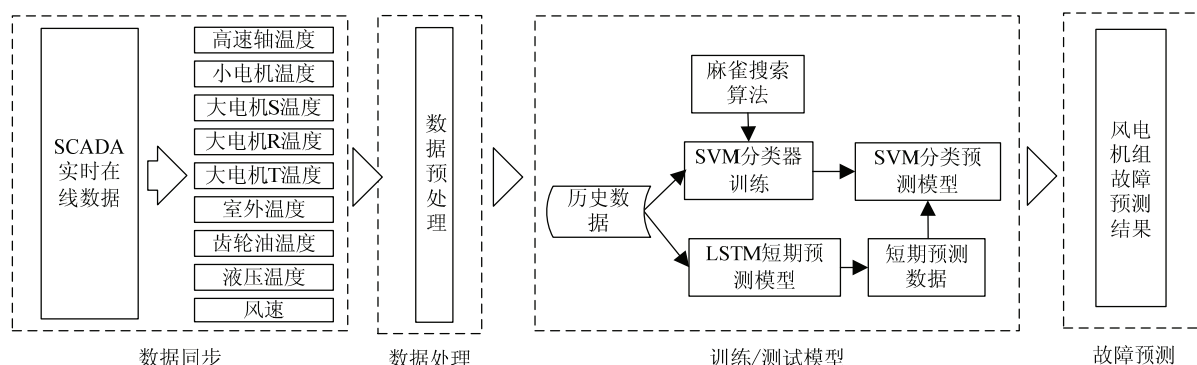


图 1 系统整体框架

Fig.1 overall framework of system

2 系统模型

2.1 长短期记忆网络 LSTM 模型

LSTM 网络是采用时间先后顺序开展反向误差传播算法进行网络训练的, 适于处理时间序列变量的预测问题, 而风电机组 SCADA 系统数据是与时间密切相关的, 故 LSTM 模型适合风电机组数据的相关预测分析.

LSTM 模型的输入为同步风电机组 SCADA 系统数据中 9 个关键数据字段的短期连续时间段内的实时和历史数据, 输出是对应 9 个特征下一时间点的预期数据, 见图 2.

2.2 支持向量机 SVM 模型

SVM 在解决二分类问题上具有良好的性能, 适于 LSTM 模型的短期预测进行是否故障判别.




图 2 LSTM 模型的输入与输出

Fig.2 input and output of LSTM

SVM 模型的输入为同步风电机组 SCADA 系统数据中 9 个关键数据字段, 将每种特征参数作为一个输入向量 x , 输入向量定义为

$$\mathbf{x} = [A_1, A_2, A_3, A_4, A_5, A_6, A_7, A_8, A_9], \quad (1)$$

式中, $A_n (n=1, \dots, 9)$ 为特征参数的值。SCADA 系统数据中风电机组运行状态有故障和正常两种。

C-SVM 的约束式为

$$y_i = [(\omega \cdot x_i) + b] \geq 1 - \xi_i \quad i = 1, \dots, l, \quad (2)$$

式中, ω, b 为超平面定义的参数; l 为 SVM 训练集数据中的帧数; ξ_i 为松弛系数。

由于 SCADA 数据的特征参数非线性, 故使用径向基函数 RBF (radial basis function) 作为内核函数 K 进行数据空间映射。 K 定义为

$$K(\mathbf{x}, x_i) = (\varphi(\mathbf{x}) \cdot \varphi(x_i)) \quad (3)$$

$$K(\mathbf{x}, x_i) = e^{-\gamma \|\mathbf{x} - x_i\|^2} \quad (4)$$

式中, γ 为内核函数的预定义参数。

SCADA 数据运行状态 (\mathbf{x}, y) 的训练集从 $R^9 \times R$ 映射到 Hilbert 空间 $\times R$ 为

$$\{(x_1, y_1), \dots, (x_l, y_l)\} = \{(\varphi(x_1), y_1), \dots, (\varphi(x_l), y_l)\} \quad (5)$$

根据下式确定超平面 $(\omega \cdot x_i) + b = 0$,

$$\min_{\omega \in H, b \in R, \xi \in R} \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^l \xi_i \quad (6)$$

$$\text{s.t.} \quad y_i = [(\omega \cdot x_i) + b] \geq 1 - \xi_i \quad i = 1, \dots, l, \quad (7)$$

$$\xi_i \geq 0 \quad i = 1, \dots, l, \quad (8)$$

式中, C 为惩罚系数。

SVM 模型由超平面的唯一解进行定义。其中

$$\omega^* = \sum_{i=1}^l \alpha_i^* y_i x_i \quad (9)$$

$$b^* = y_i - \sum_{i=1}^l \alpha_i^* y_i K(\mathbf{x}, x_i), j \in \{j | C \geq \alpha_j \geq 0\} \quad (10)$$

对于每条 SCADA 数据输入向量, 由 SVM 模型预测判别结果输出为

$$y = \text{sgn} \left(\sum_{i=1}^N y_i \alpha_i K(x_N, x) + b \right) \quad (11)$$

SVM 模型的分类过程原理见图 3, 其中 N 是支持向量 ω 的数量。




图3 SVM模型的输入与输出

Fig.3 input and output of SVM

2.3 麻雀优化算法优化 SVM 模型

麻雀搜索算法 SSA 是一种源于麻雀觅食和反捕食行为的种群智能优化算法, 具有寻优能力强、收敛速度快等优点, 适合对 SVM 模型进行优化。

在模拟测试实验中, 利用虚拟麻雀模拟寻找食物, 由 n 只麻雀组成的种群为

$$\mathbf{X} = \begin{bmatrix} x_1^1 & x_1^2 & \dots & x_1^d \\ x_2^1 & x_2^2 & \dots & x_2^d \\ \vdots & \vdots & & \vdots \\ x_n^1 & x_n^2 & \dots & x_n^d \end{bmatrix}, \quad (12)$$

式中, d 为风电机组运行状态的因变量维数, d 的值为 9, 表示 9 个特征参数。

所有麻雀的适应度值 F 表示为

$$\mathbf{F}_x = \begin{bmatrix} f([x_1^1 & x_1^2 & \dots & x_1^9]) \\ f([x_2^1 & x_2^2 & \dots & x_2^9]) \\ \vdots \\ f([x_n^1 & x_n^2 & \dots & x_n^9]) \end{bmatrix}, \quad (13)$$

在每次迭代过程中, 发现者的位置更新为

$$X_{i,j}^{t+1} = \begin{cases} X_{i,j} \cdot \exp\left(-\frac{i}{\alpha \cdot i_{\text{tem-max}}}\right) & R_2 < ST \\ X_{i,j} + Q \cdot L & R_2 \geq ST \end{cases}, \quad (14)$$

式中, t 为当前迭代次数; $i_{\text{tem-max}}$ 为最大迭代次数; $X_{i,j}$ 为第 i 个麻雀在第 j 维中的位置; α 为随机数; R_2 和 ST 分别为预警值和安全值; Q 为服从正态分布的随机数; L 为 1×9 矩阵, 每个元素均为 1。

在觅食过程中, 一些加入者会监视寻找食物的发现者并去争夺更好的食物, 加入者的位置为

$$X_{i,j}^{t+1} = \begin{cases} Q \cdot \exp\left(\frac{X_{\text{worst}}^t - X_{i,j}^t}{i^2}\right) & i > n/2 \\ X_p^{t+1} + |X_{i,j}^t - X_p^{t+1}| \cdot A^+ \cdot L, i \leq n/2 \end{cases}, \quad (15)$$

式中, X_p 和 X_{worst} 分别为最优位置和最差位置。 A 为一个 1×9 的矩阵, 元素随机赋值为 1 或 -1, 且 $A^+ = A^T (A A^T)^{-1}$ 。

在模拟测试实验中, 设意识到危险的麻雀占总量的 10% 至 20%, 这些麻雀的位置为

$$X_{i,j}^{t+1} = \begin{cases} X_{\text{best}}^t + \beta \cdot |X_{i,j}^t - X_{\text{best}}^t|, & f_i > f_g \\ X_{i,j}^t + K \cdot \left(\frac{X_{i,j}^t - X_{\text{worst}}^t}{(f_i - f_w) + \varepsilon} \right), & f_i = f_g \end{cases}, \quad (16)$$

式中, X_{best} 为当前的全局最优位置; β 为服从均值为 0、方差为 1 的正态分布控制步长; $K \in [-1, 1]$ 是一个随机数; f_i 为麻雀个体 i 的适应度值; f_g 和 f_w 分别为当前全局最佳和最差的适应度值; ε 为常数, 避免分母为 0。

2.4 风电机组 SCADA 系统数据特征分析

实验数据集为某风电场的 MADE 型号风机的 SCADA 系统后台数据，其中基础数据包括风机型号、风机类型、记录时间等静态数据，以及通过传感器采集的温度、风速、功率等共计 10 个特征值，详细说明见表 1.

表 1 风电机 SCADA 数据特征

Tab.1 data characteristics of wind turbine SCADA		
序号	名称	备注
1	sinuso	小电机温度
2	Central Hidr	液压温度
3	Generad.R	大电机 R 温度
4	Generad.S	大电机 S 温度
5	Generad.T	大电机 T 温度
6	Ambiente	高速轴温度
7	Multiplicado	齿轮油温度
8	Tiristores	室外温度
9	WindSpeed	风速（需要除 10 m/s）
10	PowerAvg	功率

首先对数据进行清洗及预处理，删除数据集中的异常样本，消除人为停机维护、调试等操作的主观影响，其次采用统计分析软件 SPSS 对特征进行主成分分析并得出特征权重，明确找出对因变量有影响的特征，进一步提高模型的准确度，具体分析结果见表 2.

表 2 特征重要性排序

Tab.2 feature importance ranking		
序号	名称	特征权重
1	Central Hidr	0.134 387 352
2	sinuso	0.130 434 783
3	Generad.R	0.130 434 783
4	Generad.S	0.130 434 783
5	Ambiente	0.108 577 075
6	Multiplicado	0.104 624 506
7	Generad.T	0.089 288 538
8	WindSpeed	0.088 814 229
9	Tiristores	0.083 003 953

由特征重要性排序可知，液压温度、小电机温度及大电机温度特征权重较大，同时也是风机监测的重要指标，对于故障预测结果有着重要的影响，同时也从另一个侧面说明通过温度等参数预测风机故障状况是可行的，同时其他参数的特征权重也均在 8%以上，因此选取这 9 个特征作为算法及模型的特征参数.

3 实验

3.1 实验环境

实验测试为云虚拟机模拟环境，硬件配置为 Intel Xeon Gold 6266C@3.00GHz CPU，8.00GB 内

存，系统软件为 64 位 Windows Server 2016 Standard 操作系统，应用软件为 Pycharm2020.1.

3.2 实验步骤

- (1) 采集数据并对数据进行预处理.
- (2) 利用历史数据训练 LSTM 模型，通过模型对未来短期数据进行预测，得到短期预测数据.
- (3) 利用历史数据训练 SVM 模型并使用 SSA 算法对 SVM 模型优化，得到的优化 SVM 模型能够判别风机运行状态.
- (4) 通过优化的 SVM 模型对 LSTM 得到的短期预测数据进行运行状态判别.
- (5) 将（4）中得到的运行状态与风力发电机组实际运行状态作比较，得到模型故障预测准确率.

3.3 数据采集和预处理

实验数据集为某风力发电场 SCADA 系统收集的历史后台运维数据，共包含电机温度、液压温度、齿轮油温度、高速轴温度、齿轮油温度、室外温度、风速和功率等 10 个维度，采样周期为 30 s，为避免季节因素对实验的影响，选取某风机 2018 年 7 月、8 月的 SCADA 数据共 63 319 条，手动删除异常值 6 814 条，其中包含停机维护、调试数据，以及不符合常理的无效数据.经处理后共计 56 478 条有效数据，将功率为正数的样本作为正常数据，将功率为 0 的样本标记为故障数据.

3.4 LSTM 模型实验

分别对 9 个参数进行 LSTM 短期预测，再将其预测得到的值结合到一起，得到新的 SCADA 数据的短期预测数据.取 10 台运行的 MADE 型号风机各 1 100 条数据，共 11 000 条数据.划分数据集，各取前 1 000 条 SCADA 数据为训练集，剩下 100 条 SCADA 数据为测试集.

首先采用训练集进行模型训练，并通过训练集后 50 条数据预测一条新数据，其次把这条新的数据添加到训练集的末尾并另存为预测结果，再通过训练集新生成的后 50 条数据再预测一条新数据.重复进行 100 次，最终得到 10 台风机预测结果各 100 条，并与测试集中的实际数据作对比.图 4 和图 5 分别为 1 号风机大电机温度和液压温度预测值与实际值的对比.




图 4 大电机温度预测值与实际值对比

Fig.4 comparison between predicted and actual large motor temperature




图 5 液压温度预测值与实际值对比

Fig.5 comparison between predicted and actual hydraulic temperature

3.5 SSA 优化 SVM 实验结果

为测试经 SSA 改进后模型的性能和准确率, 将其和未进行改进的 SVM 模型进行比较, 分别使用 SSA-SVM 和 SVM 对相同数据集进行分类预测对比实验结果见图 6 和图 7. SSA-SVM 预测结果准确率为 98.80%, SVM 预测结果准确率为 93.65%. 经过 SSA 改进的 SVM 模型的预测效果相比传统 SVM 效果有明显的提升.




图 6 SSA-SVM 预测结果散点

Fig.6 scatter plot of SSA-SVM prediction results




图 7 SVM 预测结果散点

Fig.7 scatter plot of SVM prediction results

3.6 LSTM-SSA-SVM 实验结果

LSTM 短期预测得到 10 台 MADE 型号风机各 100 条新数据, 使用优化的 SVM 对 1 000 条预测数据运行状态进行分类预测, 并将分类预测得到的结果与该时间段的风电机组的实际运行状态作比较, 预测正确的数据所占整体数据的百分比, 即为 LSTM-SSA-SVM 模型预测风电机组故障的准确率. 将 1 000 条预测数据加入训练好的 SSA-SVM 模型中进行测试, 最终得到测试集准确率为 97.90%, 结果见图 8.




图 8 LSTM-SSA-SVM 预测结果散点图

Fig.8 scatter plot of LSTM-SSA-SVM prediction results

将本文模型与原始 SVM 模型和其他文献提出的风机故障预测模型作对比, 对比结果见表 3.

通过对比可知, 本文模型的准确率均略高于其他故障预测模型, 证明其可行性和有效性, 在一定程度上提升风电机组故障预测的精度.

表 3 模型预测准确率对比

Tab.3 comparison of model prediction accuracy

序号	预测模型	准确率/%
1	本文 LSTM-SSA-SVM 模型	97.90
2	原始 SVM 模型	93.65
3	文献[13]CNN 模型	96.92
4	文献[14]RBM-SVM 模型	93.08
5	文献[15]XG-Boost 模型	97.70

4 结论

在传统 SVM 的基础上, 提出一种 SSA 优化 SVM 模型, 结合 LSTM 预测风电机组短期数据对风电机组运行状态进行分类预测. 现场数据测试实验结果表明, 该融合模型预测准确率可达 97.90%, 相比其他故障预测方法精度更高.

当前所研究的风电机组故障来源仅是温度等特征对故障的影响, 在后续的研究中, 还应该将振动、器件老化等因素结合在一起进行分析, 使风电机组的故障预测准确度更高.

参考文献(References):

- [1] 龙霞飞,杨苹,郭红霞,等.大型风力发电机组故障诊断方法综述[J].电网技术,2017,41(11):3 480-3 491.
LONG Xiafei,YANG Ping,GUO Hongxia,et al.Review of fault diagnosis methods for large wind turbines[J].Power System Technology, 2017,41(11):3 480-3 491.
- [2] 曾军,陈艳峰,杨苹,等.大型风力发电机组故障诊断综述[J].电网技术,2018,42(3):849-860.
ZENG Jun,CHEN Yanfeng,YANG Ping,et al.Review of fault diagnosis methods of large-scale wind turbines[J].Power System Technology, 2018,42(3):849-860.
- [3] 陈雪峰,李继猛,程航,等.风力发电机状态监测和故障诊断技术的研究与进展[J].机械工程学报,2011,47(9):45-52.
CHEN Xuefeng,LI Jimeng,CHENG Hang,et al.Research and application of condition monitoring and fault diagnosis technology in wind turbines[J].Journal of Mechanical Engineering,2011,47(9):45-52.
- [4] 金晓航,孙毅,单继宏,等.风力发电机组故障诊断与预测技术研究综述[J].仪器仪表学报,2017,38(5):1 041-1 053.
JIN Xiaohang,SUN Yi,SHAN Jihong,et al.Fault diagnosis and prognosis for wind turbines:an overview[J].Chinese Journal of Scientific Instrument,2017,38(5):1 041-1 053.
- [5] 安学利,蒋东翔,陈杰,等.基于 ITD 和 LS-SVM 的风力发电机组轴承故障诊断[J].电力自动化设备,2011,31(9):10-13.
AN Xueli,JIANG Dongxiang,CHEN Jie,et al.Bearing fault diagnosis based on ITD and LS-SVM for wind turbine[J].Electric Power Automation Equipment,2011,31(9):10-13.
- [6] 梁颖,方瑞明.基于 SCADA 和支持向量回归的风电机组状态在线评估方法[J].电力系统自动化,2013,37(14):7-12,31.
LIANG Ying,FANG Ruiming.An online wind turbine condition assessment method based on SCADA and support vector regression[J].Automation of Electric Power Systems,2013,37(14):7-12,31.
- [7] 李状,柳亦兵,滕伟,等.基于粒子群优化 KFCM 的风电齿轮箱故障诊断[J].振动.测试与诊断,2017,37(3):484-488,626-627.
LI Zhuang,LIU Yibing,TENG Wei,et al.Fault diagnosis of wind turbine gearbox based on KFCM optimized by particle swarm optimization[J].Journal of Vibration,Measurement & Diagnosis,2017,37(3):484-488, 626-627.
- [8] 王皓,周峰.基于小波包和 BP 神经网络的风机齿轮箱故障诊断[J].噪声与振动控制,2015,35(2):154-159.
WANG Hao,ZHOU Feng.Fault diagnosis of wind turbine gearbox based on wavelet packet and back propagation neural network[J].Noise and Vibration Control,2015,35(2):154-159.
- [9] 沈艳霞,周文晶,纪志成,等.基于小波包与 SVM 的风电变频器故障诊断[J].太阳能学报,2015,36(4):785-791.
SHEN Yanxia,ZHOU Wenjing,JI Zhicheng,et al.Fault diagnosis of converter used in wind power generation based on wavelet packet analysis and SVM[J].Acta Energaie Solaris Sinica,2015,36(4):785-791.
- [10] 胡海峰,安茂春,秦国军,等.基于隐半 Markov 模型的故障诊断和故障预测方法研究[J].兵工学报,2009,30(1):69-75.
HU Haifeng,AN Maochun,QIN Guojun,et al.Study on fault diagnosis and prognosis methods based on hidden semi-markov model[J].Acta Armamentarii,2009,30(1):69-75.
- [11] 胡为,高雷,傅莉.基于最优阶次 HMM 的电机故障诊断方法研究[J].仪器仪表学报,2013,34(3):524-530.
HU Wei,GAO Lei,FU Li.Research on motor fault detection method based on optimal order hidden Markov model[J].Chinese Journal of Scientific Instrument,2013,34(3):524-530.
- [12] 李刚,齐莹,李银强,等.风力发电机组故障诊断与状态预测的研究进展[J].电力系统自动化,2021,45(4):180-191.
LI Gang,QI Ying,LI Yinqiang,et al.Research progress on fault diagnosis and state prediction of wind turbine[J].Automation of Electric Power Systems,2021,45(4):180-191.
- [13] 梁川.基于一维卷积神经网络的风机故障预测[J].科技创新与应用,2020(32):132-135.
LIANG Chuan.Fault prediction of wind turbine based on one dimensional convolution neural network[J].Technology Innovation and Application,2020(32):132-135.
- [14] 张鑫,徐遵义,何慧茹,等.基于 RBM 和 SVM 的风电机组叶片开裂故障预测[J].电力系统保护与控制,2020,48(15):134-140.
ZHANG Xin,XU Zunyi,HE Huiru,et al.Wind turbine blade cracking fault prediction based on RBM and SVM[J].Power System Protection and Control,2020,48(15):134-140.
- [15] 王桂兰,赵洪山,米增强.XGBoost 算法在风机主轴轴承故障预测中的应用[J].电力自动化设备,2019,39(1):73-77,83.
WANG Guilan,ZHAO Hongshan,MI Zengqiang.Application of XGBoost algorithm in prediction of wind motor main bearing fault[J].Electric Power Automation Equipment,2019,39(1):73-77,83.
- [16] KULKANI C,BISWAS G,KOUTSOUKOS X,et al.Integrated diagnostic/prognostic experimental setup for capacitor degradation and health monitoring[J].Institute of Electrical and Electronics Engineering,2010:1-7.
- [17] PATIL N,CELAYA J,DAS D,et al.Precursor parameter identification for insulated gate bipolar transistor(IGBT) prognostics[J].IEEE Transactions on Reliability,2009,58(2):271-276.
- [18] WANG Y,PENG Y Z,ZI Y Y,et al.A two-stage data-driven based prognostic approach for bearing degradation problem[J].IEEE Transactions on Industrial Informatics,2016,12(3):924-932.
- [19] ZAHER A,MCARTHUR S D J,INFIELD D G.Online wind turbine fault detection through automated SCADA data analysis[J].Wind Energy,2009,12(6):574-593.
- [20] RODRIGUEZ-LOPEZ M A,LOPEZ-GONZALEZ L M,LOPEZ-OCHOA L M,et al.Development of indicators for the detection of equipment malfunctions and degradation estimation based on digital signals(alarms and events) from operation SCADA[J].Renewable Energy,2016,99(12):224-236.