

文章编号: 1001-8360(2023)09-0094-09

基于注意力机制和双向 LSTM 网络的轨道电路故障预测研究

戴胜华, 那 岚, 梁续继

(北京交通大学 电子信息工程学院, 北京 100044)

摘 要: 基于铁路电务段轨道电路微机监测系统数据记录, 提出一种基于注意力机制和双向长短期记忆网络的轨道电路故障预测方法。首先按照一定时间间隔记录并处理 ZPW-2000A 轨道电路微机监测数据, 并使用合成少数类过采样算法进行数据扩充; 然后基于注意力机制和双向 LSTM 网络构建轨道电路故障预测模型; 考虑到神经网络超参数组合对模型性能有较大影响, 使用基于贝叶斯采样的 Hyperband 算法优化轨道电路故障预测模型的超参数组合, 再利用 Adam 算法优化模型参数, 从而了解故障发生前轨道电路状态随时间的变化情况, 实现对轨道电路故障状态的预测。实验表明: 该模型能够准确预测轨道电路故障状态, 从而指导电务段一线工作人员在故障发生前介入, 提升轨道电路维护效率和运行效率。本研究为轨道电路故障预测相关研究提供一种新思路。

关键词: 注意力机制; 双向 LSTM; 故障诊断; 故障预测; 无绝缘轨道电路

中图分类号: U284.2 **文献标志码:** A **doi:** 10.3969/j.issn.1001-8360.2023.09.010

Research on Fault Prediction of Track Circuit Based on Bidirectional LSTM and Attention Mechanism

DAI Shenghua, NA Lan, LIANG Xuji

(School of Electronics and Information Engineering, Beijing Jiaotong University, Beijing 100044, China)

Abstract: Based on the records of the track circuit microcomputer monitoring system in the communication and signal section, a method for predicting track circuit faults based on attention mechanism and bidirectional long short-term memory (Bidirectional LSTM) was proposed. First, a sequence of data over time was built based on the monitoring data of track circuit at a certain interval, followed by data expanding through synthetic minority oversampling technique. Then a fault prediction model was established based on attention mechanism and Bidirectional LSTM, to train the model parameters using Adam algorithm. Finally, considering the significant influences of the choice of the hyper parameters of neural network model on the performance of prediction model, the Bayesian optimization Hyperband algorithm was used to optimize the hyper parameters, to figure out the variation of track circuit status with time before the occurrence of faults, to realize the prediction of track circuit faults in the future. The experiments show that the model can accurately predict and discriminate the track circuit faults, therefore can help and direct staffs of communication and signal section to intervene before the occurrence of faults, to enhance the maintenance efficiency and operation efficiency of the track circuit. This study provides a new idea for the research of track circuit fault prediction.

Key words: attention mechanism; bidirectional long short-term memory; fault diagnosis; fault prediction; jointless track circuit

无绝缘轨道电路作为我国铁路列车运行控制系统中应用范围最广、使用时间最长的信号安全设备,其工

作性能的优劣对列车运行控制系统的运行状态有着直接影响。ZPW-2000A 无绝缘轨道电路是我国铁路区间常用的轨道电路制式^[1], 由于其大量部件位于室外, 难免会受自然环境因素影响而发生故障, 这将对铁路运行效率造成不利影响, 甚至造成安全事故^[2]; 目前轨道电路的维护、检测方法仍然严重依赖人工经验, 这又

收稿日期: 2021-12-23; 修回日期: 2022-04-11

基金项目: 国家自然科学基金(61833001)

第一作者: 戴胜华(1962—), 男, 安徽芜湖人, 教授, 硕士。

E-mail: dsh@bjtu.edu.cn

通信作者: 那 岚(1998—), 男, 辽宁丹东人, 硕士研究生。

E-mail: nl2020@bjtu.edu.cn

会对轨道电路故障处理的可靠性与效率造成负面影响^[3]。因此需要使用更加有效的技术手段提升轨道电路维护检修能力,提高轨道电路运行稳定性。

故障诊断是指利用各种检查方法判断系统和设备是否存在故障,从而进一步确定故障所在位置的技术手段。目前 ZPW-2000A 无绝缘轨道电路智能故障诊断领域的研究有:使用神经网络拟合轨道电路微机监测数据与故障状态之间的高维特征映射关系,实现轨道电路故障诊断^[4-5];基于粗糙集与模糊认知图对轨道电路微机监测数据进行属性约减与特征提取,构建分类器实现轨道电路故障诊断^[6];利用组合决策树拟合轨道电路故障诊断规则,构建专家系统完成故障识别^[7]。以上方法虽然能较为精确地对已发生的轨道电路故障进行诊断,但是并不能对将要发生的故障提前预警。因此对提升轨道电路维护检修能力效果有限。

故障预测是指故障尚未发生,但通过某些迹象判断设备可能存在异常并确认设备是否存在故障或故障趋势的技术手段。因此故障预测技术能通过预判轨道电路未来工作状态,引导人工提前介入以避免故障的发生,达到提高轨道电路运行稳定性与维护检修能力的目的。文献[8]基于支持向量机和 GM(1,1)建立轨道电路故障预测模型,并通过仿真证明模型有效性;文献[9]基于灰度理论和专家系统建立轨道电路故障预测模型,并通过仿真证明该模型能够有效预测故障;文献[10]通过构建深度置信网络以及隐式半马尔科夫模型实现轨道电路寿命预测,通过模拟仿真证明模型预测的准确性;文献[11]利用长短期记忆网络(Long-Short Term Memory, LSTM)实现对未来一段时间内轨道电路补偿电容故障数量预测,实验结果表明该方法能够较准确预测补偿电容故障数量;文献[12]基于 GM(1,1)理论建立轨道电路故障预测模型,并通过实验证明模型预测的有效性。虽然目前国内外轨道电路故障预测相关研究已取得一定进展,但仍有较大局限性。例如,专家系统知识获取困难、支持向量机只能研究二分类问题、普通 BP 神经网络难以处理时间序列信息、深度置信网络泛化性较弱等。因此有必要针对轨道电路故障预测展开更为深入的研究。

本文首先通过轨道电路微机监测系统获取真实数据;进一步确定轨道电路故障类型,选择合适的特征开展轨道电路故障预测研究,使用合成少数类过采样算法(Synthetic Minority Oversampling Technique, SMOTE)对数据进行扩充;然后基于注意力机制和 LSTM 网络搭建轨道电路故障预测模型;再使用基于贝叶斯采样的 Hyperband 算法(Bayesian Optimization

Hyperband, BOHB)优化当前模型结构下的超参数组合;在此基础上使用扩充后的数据训练故障预测模型;最后使用真实数据对模型故障预测性能进行评估。实验结果表明:该模型能够较为准确地预测未来一段时间内轨道电路故障状态,从而提升轨道电路维护检修能力与运行稳定性。

1 问题分析

1.1 ZPW-2000A 轨道电路组成

ZPW-2000A 轨道电路总体结构示意图见图 1。图 1 中,每个轨道区段均由发送端、发送端调谐区、主轨道电路、接收端调谐区、接收端构成^[13];发送端与接收端分别由发送器或接收器、防雷单元以及传输电缆构成;在主轨道电路之间等间距设有补偿电容;发送端和接收端均设有调谐区,以保证相邻轨道电路区段电气隔离和本轨道电路区段内信号正常传输。

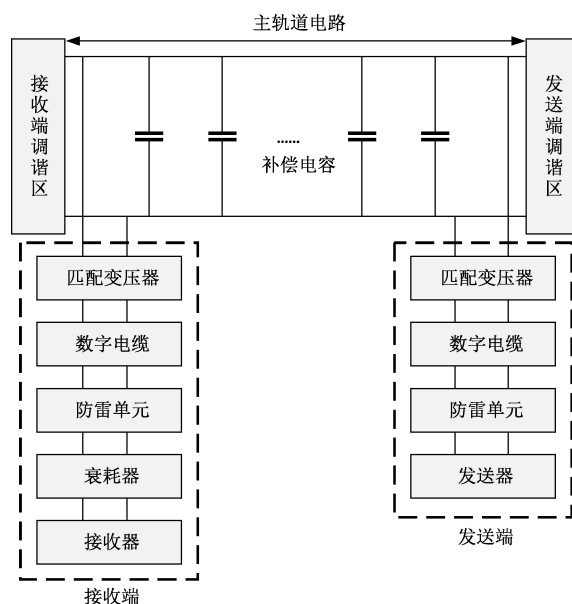


图 1 ZPW-2000A 轨道电路总体结构示意图

ZPW-2000A 轨道电路各个轨道区段的信号通过发送器注入该区段主轨道电路和发送端调谐区分别传输,两路信号最终分别到达本轨道区段接收端和相邻轨道区段接收端。本轨道区段接收端将同步获取两个轨道区段之间的调谐区状态,在判定两路信号准确无误后轨道继电器将进行相应的动作,以此表示本轨道区段的占用状态。

1.2 轨道电路故障类别

基于某电务段轨道电路微机监测数据和故障处理记录,总结出 ZPW-2000A 轨道电路故障状态与正常调整状态,见表 1。表 1 中, F0 为正常调整状态, F1~F8 为 8 种故障状态。

表 1 ZPW-2000A 轨道电路故障状态与正常调整状态

状态编号	状态	状态编号	状态
F0	正常状态	F5	接收端数字电缆故障
F1	发送器故障	F6	接收端衰耗器故障
F2	发送端数字电缆故障	F7	发送端匹配变压器故障
F3	道砟电阻过低	F8	接收端匹配变压器故障
F4	补偿电容故障		

1.3 轨道电路故障预测原理分析

ZPW-2000A 轨道电路发生故障的本质是轨道电路参数突变,从而引发轨道电路信号幅值经历暂态过渡到稳态^[14]。而事物在突变质变之前往往伴随着缓变量变,这一普遍规律为轨道电路故障预测提供了依据。对于拥有相同参数的 ZPW-2000A 轨道电路,不同时间、地点、环境下其电压曲线波动情况在总体上是一致的^[15],因此能够基于微机监测数据对轨道电路相关监测信号的时变趋势进行分析,探究其与轨道电路故障之间的关系,进而实现轨道电路故障预测。

2 预测模型

2.1 数据采集与预处理

本文中原始数据均源于沈阳铁路局某电务段 ZPW-2000A 轨道电路微机监测设备采集结果,并根据相应故障处理调查报告对原始数据所对应的故障类型进行标注,根据微机监测原始数据选择故障预测模型输入特征量。轨道电路故障预测特征量选取见表 2。

表 2 轨道电路故障预测特征量选取

特征量 编号	名称	特征量 编号	名称
M0	发送功出电压	M5	电缆侧接收小轨道电压
M1	发送功出电流	M6	主轨入电压
M2	电缆侧发送电压	M7	小轨入电压
M3	电缆侧发送电流	M8	主轨出电压
M4	电缆侧接收主轨道电压	M9	小轨出电压

为保证输入数据具体形式的合理性,通过查阅轨道电路故障调查报告以及文献[16],并结合电务段工作人员实际工作经验,选择以故障发生前 24 h 至故障发生前 108 h 的数据,以 24 h 为固定间隔求取各特征量在这段时间内极差的绝对值,其计算式为

$$x_{pf} = |\max(X) - \min(X)| \tag{1}$$

式中: x_{pf} 为预处理结果,作为故障预测模型输入; X 为该特征量在 24 h 范围内的微机监测数据; $\max(X)$ 、 $\min(X)$ 分别为 X 的最大值、最小值。

2.2 数据扩充

由于轨道电路微机监测记录中正常调整状态数据与故障状态数据数量不均衡,不同故障状态数据间数量亦不均衡,故障预测模型训练效果将受到不良影响,

故本文采用 SMOTE 算法减少非均衡样本的不对称性,避免由于样本分布不均影响模型训练效果。SMOTE 算法在数据生成领域有着广泛应用^[17],其基本原理是针对样本 x ,从其 k 个近邻同类样本中随机选择若干个样本,并对每个近邻 \bar{x} 通过随机线性插值的方法构造新样本 x_{new} ,其计算式为

$$x_{new} = x + \text{rand}(0,1) \cdot (\bar{x} - x) \tag{2}$$

式中: $\text{rand}(0,1)$ 为 0~1 之间服从均匀分布的随机数。与随机采样扩充算法相比,SMOTE 算法得到的扩充数据具有更佳的普适性,能够有效克服随机复制过采样法新生成数据与原始样本过拟合的缺点。因此本文利用 SMOTE 算法扩充数据集,训练轨道电路故障预测模型。

2.3 预测模型框架

基于注意力机制和双向 LSTM 网络的轨道电路故障预测模型框架见图 2。图 2 中,输入层对轨道电路故障预测数据集进行预处理;隐含层中包含双向 LSTM 网络以及注意力层;输出层由 Flatten 层、Dropout 层、Softmax 层构成。下面分别对输入层、隐含层、输出层,以及模型训练相关内容进行详细介绍。

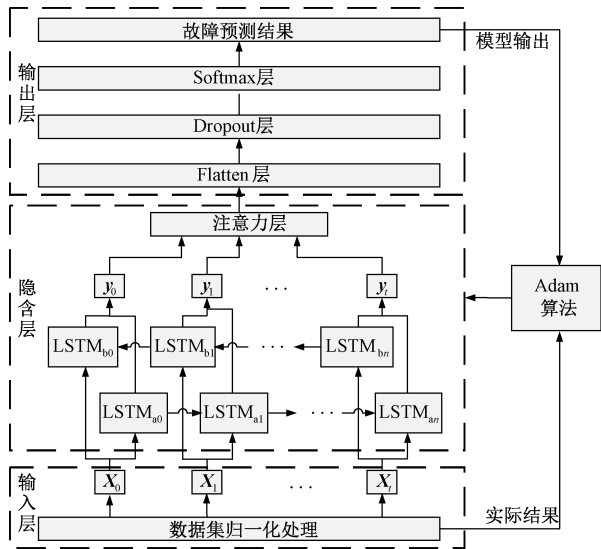


图 2 轨道电路故障预测模型框架

2.3.1 输入层

通过输入层将数据集中每一组数据进行归一化处理,其中每个时刻样本数据的形式为 $X_t = [x_0, x_1, \dots, x_8, x_9]$, $x_0 \sim x_9$ 的计算式为

$$x_k = \frac{x_{pf}^k}{\sum_{b=0}^9 x_{pf}^b} \quad k = 0, 1, 2, \dots, 9 \tag{3}$$

数据归一化有助于增强预测模型的训练速度,增强模型训练过程中的收敛性。

2.3.2 隐含层

LSTM 网络最早由 Hochreiter 等^[18]于 1997 年提出,解决了传统循环神经网络的梯度累积问题^[19]。LSTM 单元结构见图 3。




图 3 LSTM 单元结构

图 3 中, C_t 为当前时刻细胞单元; h_t 为当前时刻细胞输出; f_t 为当前时刻遗忘门; i_t 为当前时刻输入门; σ 为 Sigmoid 激活函数; f_t, i_t 用于计算前一时刻 LSTM 细胞单元 C_{t-1} 中各特征的权重, 由 X_t, h_{t-1} 经由 Sigmoid 激活函数计算得到, f_t, i_t 均为向量, 每个元素值均位于 $[0, 1]$ 之间, 向量元素等于 1 意味着对应特征在计算中被完全保留, 等于 0 意味着对应特征在计算中被完全舍弃; \otimes 为计算 2 个向量的 Hadamard 积; \oplus 为 2 个向量求和; \bar{C}_t 由当前时刻输入状态 X_t 和上一时刻 LSTM 单元输出 h_{t-1} 相加后通过 \tanh 激活函数得到; o_t 为输出门的中间计算结果; h_t 为当前时刻 LSTM 的最终输出。各变量间关系为

$$C_t = f_t C_{t-1} + i_t \bar{C}_t \quad (4)$$

$$f_t = \sigma(W_f[h_{t-1}, X_t] + b_f) \quad (5)$$

$$i_t = \sigma(W_i[h_{t-1}, X_t] + b_i) \quad (6)$$

$$\bar{C}_t = \tanh(W_{\bar{C}}[h_{t-1}, X_t] + b_{\bar{C}}) \quad (7)$$

$$o_t = \sigma(W_o[h_{t-1}, X_t] + b_o) \quad (8)$$

$$h_t = o_t \cdot \tanh(C_t) \quad (9)$$

式中: $W_f, b_f, W_i, b_i, W_{\bar{C}}, b_{\bar{C}}, W_o, b_o$ 均为模型中待训练的参数。

传统 LSTM 网络某一时刻的输出只与之前时刻的输入有关。而对于故障预测而言, 了解该时刻之后的信息有着同样的重要性。因此采用双向 LSTM 网络实现过去信息和未来信息的综合利用。双向网络中包括前向网络和后向网络, 其中, 前向网络得到时序输入 $[x_0, x_1, \dots, x_8, x_9]$, 并经过计算得到输出 h_t ; 后向网络按照与前向网络相反时序 $[x_9, x_8, \dots, x_1, x_0]$ 获得输入信息, 经过计算得到输出结果 h'_t 。对于任意时刻的双向 LSTM 网络, 其输出可表示为 $[h_t, h'_t]$ 。

注意力机制最初被用于计算机视觉领域^[20], 目前

已成为神经网络结构的重要组成部分, 并在自然语言处理^[21]、语音处理^[22]、计算机视觉^[23]等领域有着大量应用。注意力机制可以利用人类视觉机制进行直观解释。例如人类视觉系统更倾向于关注图像中辅助判断的部分信息而忽略掉不相关的信息^[24]。实验证明, 注意力机制能够大幅改善循环神经网络的使用效果^[25]。

由于轨道电路特征数据随轨道电路自身状态而波动, 需要相邻时刻数据判断某时刻轨道电路特征数据对应何种状态; 同时值得注意的是, 距离当前时刻时间较远但是内容重要的数据应与距离当前时刻时间较近数据具有类似重要的影响; 双向 LSTM 网络在任意时刻的输出结果包含相邻时刻数据信息。因此, 在此基础上引入注意力机制将相邻时刻数据进行加权计算, 以表示其对于当前时刻数据的重要程度, 进而提升模型性能^[26]。

注意力层结构见图 4。图 4 中, p_1, s, p_2 分别为任意时刻由注意力层产生的中间量; τ 为根据给定方式置换输入的维度, 在此模型中为置换对应输入的第 1、第 2 个维度, 其作用是调整数据格式便于后续计算; Softmax 层的作用是计算每个输入特征的权重, 其计算式为

$$s_k = \frac{\exp(p_{1k})}{\sum_{b=0}^9 \exp(p_{1b})} \quad k = 0, 1, \dots, 9 \quad (10)$$

式中: p_{1k}, p_{1b}, s_k 分别为向量 p_1, s 中的每个元素。




图 4 注意力层结构

2.3.3 输出层

轨道电路故障预测模型的输出层包括 Flatten 层、Dropout 层和 Softmax 层。Flatten 层的作用是将多维数据调整为一维以便于后续计算。Dropout 层的每个神经元在训练过程中以概率 p 被保留, 在测试阶段将每个神经元的权重矩阵 W 乘以 p , Dropout 层的作用是保证模型的泛化性和鲁棒性^[27]。Softmax 层利用 Softmax 函数保证输出结果的归一性, 其计算式为

$$\hat{y}_k = \frac{\exp(a_k)}{\sum_{b=0}^9 \exp(a_b)} \quad k = 0, 1, \dots, 9 \quad (11)$$

式中: a_b 为神经网络各个输出单元的输出值; a_k 为神经网络第 k 个输出单元的输出值; \hat{y}_k 为神经网络输出的归一化结果, 代表对应输入数据为第 k 类故障的

概率。

Softmax 层输出结果格式为 $\hat{\mathbf{y}} = [\hat{y}_0, \hat{y}_1, \dots, \hat{y}_7, \hat{y}_8]$, $\hat{y}_0 \sim \hat{y}_8$ 分别对应轨道电路正常调整状态以及 8 种故障状态。输出结果中的最大值对应的状态即为模型预测结果。

2.3.4 模型训练

模型在训练过程中将模型输出结果 $\hat{\mathbf{y}}$ 与数据集标签 \mathbf{y} 的均方根误差作为损失函数,再根据 Adam 算法利用损失更新模型参数^[28],则模型损失 $Loss(\mathbf{y}, \hat{\mathbf{y}}, \boldsymbol{\theta})$ 为

$$Loss(\mathbf{y}, \hat{\mathbf{y}}, \boldsymbol{\theta}) = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2 \quad (12)$$

式中: m 为每一次训练过程数据的数量。

设预测模型 t 时刻待更新的模型参数为 θ_t , 则当前时刻梯度 g_t 可表示为

$$g_t = \nabla_{\theta} Loss(\mathbf{y}, \hat{\mathbf{y}}, \theta_{t-1}) \quad (13)$$

则 Adam 算法更新参数 θ_t 的更新式为

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (14)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (15)$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t} \quad (16)$$

$$\hat{v}_t = \frac{v_t}{1 - \beta_2^t} \quad (17)$$

$$\theta_t = \theta_{t-1} - \frac{\alpha \hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon} \quad (18)$$

式中: m_t 为 t 时刻梯度的指数移动平均数, $m_0 = 0$; β_1 为指数衰减率,通常取 0.9; v_t 为梯度平方的指数移动平均数, $v_0 = 0$; β_2 为指数衰减率,通常取 0.999。由于 $m_0 = 0$ 且 $v_0 = 0$, 因此在训练初期需要对 m_t, v_t 进行修正, \hat{m}_t, \hat{v}_t 为修正后结果。 α 为学习率, $\alpha = 0.001$ 。为避免式(18)分母为 0, 添加一常量 $\varepsilon, \varepsilon = 10^{-8}$ 。由式(14)~式(18)可知, Adam 算法能够从梯度均值及梯度平方两个角度进行自适应调节梯度更新。

3 超参数优化

故障预测模型所需要优化的超参数包括 LSTM 网络神经元个数 n_{LSTM} 、Dropout 概率 p 、故障预测模型初始学习率 lr 、数据批量大小 n_{batch} 、迭代次数 n_{epoch} 。将故障预测模型记作 $Model(n_{\text{LSTM}}, p, lr, n_{\text{batch}}, n_{\text{epoch}})$ 。各种超参数的不同组合方式会对故障预测模型的运行效能产生较大影响,故采用 BOHB 算法优化确定故障预测模型超参数组合。

BOHB 超参数优化算法引入预算的概念,并在超参数选取环节采用贝叶斯优化方法进行采样,使得该

算法能够借鉴历史采样超参数建立模型的表现,高效选择超参数采样的探索方向从而快速找到优秀的超参数^[29-30]。BOHB 超参数优化算法架构见图 5。图 5 中,包含算法初始化、迭代寻优、确定优化超参数 3 大部分。

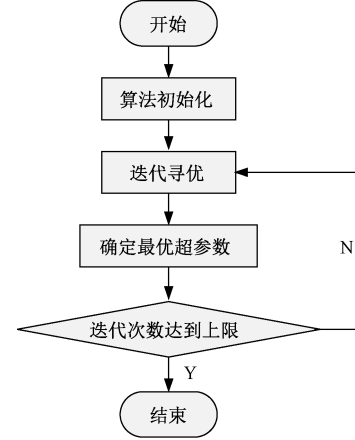


图 5 BOHB 超参数优化算法架构

3.1 算法初始化

将故障预测模型待寻优超参数 $n_{\text{LSTM}}, p, lr, n_{\text{batch}}, n_{\text{epoch}}$, 组合 $(n_{\text{LSTM}}, p, lr, n_{\text{batch}}, n_{\text{epoch}})$, 定义为 BOHB 超参数优化算法的 5 维可行域 Ω , 该可行域中各个维度的定义域为

$$\begin{cases} n_{\text{LSTM}}^{\min} \leq n_{\text{LSTM}} \leq n_{\text{LSTM}}^{\max} \\ p^{\min} \leq p \leq p^{\max} \\ lr^{\min} \leq lr \leq lr^{\max} \\ n_{\text{batch}}^{\min} \leq n_{\text{batch}} \leq n_{\text{batch}}^{\max} \\ n_{\text{epoch}}^{\min} \leq n_{\text{epoch}} \leq n_{\text{epoch}}^{\max} \\ n_{\text{LSTM}}, n_{\text{batch}}, n_{\text{epoch}} \in \mathbf{Z}^+ \end{cases} \quad (19)$$

式中: \mathbf{Z}^+ 为正整数集; $n_{\text{LSTM}}^{\min}, p^{\min}, lr^{\min}, n_{\text{batch}}^{\min}, n_{\text{epoch}}^{\min}$ 分别为对应超参数取值的下界; $n_{\text{LSTM}}^{\max}, p^{\max}, lr^{\max}, n_{\text{batch}}^{\max}, n_{\text{epoch}}^{\max}$ 分别为对应超参数取值的上界。

设置单组超参数组合所能分配的最大预算为 R , 每轮迭代参数淘汰比例为 η , 则总预算 B 为

$$B = (s_{\max} + 1) R \quad (20)$$

$$s_{\max} = \lfloor \log_{\eta} R \rfloor \quad (21)$$

同时设置寻优算法迭代次数上限为 N , 并初始化候选超参数集合 $T = \emptyset$, 以及候选超参数模型损失集合 $L = \emptyset$ 。

3.2 迭代寻优

迭代寻优过程主要分为 6 个步骤, 下面针对每一个步骤分别展开详细介绍。

Step1 从集合 $S = \{s_n \mid s_n = 0, 1, \dots, s_{\max} - 1, s_{\max}\}$ 中依照元素顺序依次不重复地选取元素 s_n , 令 $s = s_n$ 。

Step2 根据单组超参数组合所能分配的最大预

算 R 、每轮迭代参数淘汰比例 η 、总预算 B 、以及 s 计算超参数采样数量 n 和单组超参数实际所能分配的预算 r ，然后从可行域 Ω 中选取 n 组超参数^[30] 分别构建故障预测模型。 n 、 r 的计算式为

$$n = \frac{B}{R} \frac{\eta^s}{(s+1)} \quad (22)$$

$$r = R\eta^{-s} \quad (23)$$

Step3 将预算 r 分配给每一个超参数组合对应的模型并进行交叉训练验证,得到不同超参数组合对应的模型损失。按照模型损失值的大小从小到大对超参数组合进行排序,按照淘汰比例 η 剔除排名靠后的超参数组合,并进入 Step4。 i 的值等于 Step2 的执行次数减 1; r 为

$$r = r\eta^i \quad (24)$$

Step4 对剩余的超参数组合再次重复执行 Step3 中的计算过程,共 s 次。

Step5 将最终剩余的超参数组合加入集合 T , 对应的模型损失加入集合 L 。

Step6 若集合 S 还未被完全遍历则重复 Step1 ~ Step6, 否则结束超参数迭代寻优。

3.3 确定优化超参数

在完成迭代寻优的步骤后,根据其结果从集合 L 中选取值最小的元素,对照集合 T 所找到的超参数组合 $(n_{\text{LSTM}}^{\text{target}}, p^{\text{target}}, lr^{\text{target}}, n_{\text{bach}}^{\text{target}}, n_{\text{epoch}}^{\text{target}})$ 即为所求。

4 实验结果与分析

4.1 模型超参数寻优

基于沈阳铁路局某电务段 2021 年 7~9 月轨道电路微机监测系统数据记录,进行数据预处理获得每种轨道电路状态各 100 组数据,并根据故障处理报告进行分类标注。超参数寻优空间为 Ω 的具体设置为: $n_{\text{LSTM}} \in \{4, 8, 16, 32, 64\}$, $p \in \{0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7\}$, $lr \in \{0.01, 0.02, 0.03, 0.04, 0.05\}$, $n_{\text{bach}} \in \{8, 16, 32, 64\}$, $n_{\text{epoch}} \in [5, 15]$ 。本文将模型训练使用数据量定义为预算,单组超参数最多使用整个训练集进行训练,即单组超参数最多使用整个数据集, $R=100\%$ 。设定每轮迭代参数淘汰比例为 2:1,即 $\eta=2$ 。采用 5 折交叉验证对模型性能进行评估,优化算法迭代次数设置为 100。最终得到模型的超参数为 $\text{Model}(n_{\text{LSTM}}, p, lr, n_{\text{bach}}, n_{\text{epoch}}) = \text{Model}(64, 0.6, 0.04, 32, 13)$ 。故障预测模型超参数优化过程中验证集损失与超参数寻优算法迭代次数的关系见图 6。

4.2 模型训练与测试

为评估模型的应用效能,根据寻优得到的超参数组合搭建模型结构,使用训练集数据优化模型参数。




图6 验证集损失与超参数寻优算法迭代次数的关系

故障预测模型训练集识别率与训练代数的关系见图 7。由图 7 可见,最终模型在训练集上的故障预测准确率为 93.3%。




图7 训练集识别率与训练代数的关系

基于沈阳铁路局某电务段 2021 年 7~9 月轨道电路微机监测系统数据记录以及故障处理报告构建测试集。测试集包含轨道电路 F0~F8 状态原始数据各 20 组。基于注意力机制的双向 LSTM 故障预测模型混淆矩阵见图 8。由图 8 可见,该模型对各类故障均具有较高的预测精度,测试集预测总体正确率为 95.6%。

4.3 模型对比实验

为充分说明本文所提出轨道电路故障预测模型的优越性,将基于注意力机制的双向 LSTM 网络模型与传统深度学习模型进行进一步对比实验,下面针对实验结果进行详细介绍与分析。

4.3.1 与传统深度学习模型对比

首先将 LSTM 模型与经典 RNN、GRU 模型进行对比实验,每个模型的设置均为 $\text{Model}(64, 0.6, 0.04, 32, 13)$,使用训练集对各个模型分别展开训练,训练过程对比见图 9。

训练结束后使用测试集数据分别研究每个故障的




图 8 基于注意力机制的双向 LSTM 故障预测模型混淆矩阵




图 9 LSTM 与 GRU、RNN 模型训练过程对比

预测效果。LSTM、GRU、RNN 故障预测模型结果对比见表 3。

表 3 LSTM、GRU、RNN 故障预测模型结果对比

模型	测试集识别率/%	测试集损失
LSTM	85.4	0.586 3
GRU	83.2	0.764 6
RNN	71.3	0.892 1

从图 9、表 3 的实验结果可见,由于内部结构中包含有门控单元,因此 LSTM、GRU 模型相较于传统 RNN 模型在最终故障预测效果上均具有明显的优势^[18,31];由于 LSTM 模型与 GRU 模型的实践效果大体相当,因此需要根据不同研究内容具体问题具体分析^[32]。从上述实验结果可以发现,虽然 GRU 模型由于结构较为简单,收敛速度比 LSTM 模型相对较快,但是对于本文的研究内容而言其最终预测正确率略逊于 LSTM 模型,因此本文选择 LSTM 模型展开相关研究。

4.3.2 单、双向网络对比

在确定 LSTM 网络作为轨道电路故障预测模型的主要部分之后,继续探究双向网络架构对经典单向 LSTM 网络故障预测模型的增强效果。将双向 LSTM 网络与单向 LSTM 网络故障预测模型参数均设置为

$Model(64,0.6,0.04,32,13)$,并使用训练集进行训练,在训练完成后利用测试集数据进行测试。单向 LSTM 和双向 LSTM 故障预测模型结果对比见表 4。

表 4 单向 LSTM 和双向 LSTM 故障预测模型结果对比

模型	测试集识别率/%	测试集损失
双向 LSTM	90.9	0.421 7
单向 LSTM	87.4	0.568 3

由表 4 可见,由于双向网络能够获得输入数据的上下文特征信息,从而消除时间序列特征中的不确定性^[33],使得双向 LSTM 模型相较于单向 LSTM 模型在测试集正确率上得以提升,故本文选择双向 LSTM 作为故障预测模型的主体结构。

4.3.3 注意力机制对比

下面进一步对比注意力机制对双向 LSTM 网络故障预测模型的效果提升。故障预测模型参数均设置为 $Model(64,0.6,0.04,32,13)$,并使用训练集进行训练,在训练完成后利用测试集数据进行测试。双向 LSTM 与基于注意力机制的故障预测结果对比见表 5。

表 5 双向 LSTM 与基于注意力机制的故障预测结果对比

模型	测试集识别率/%	测试集损失
双向 LSTM+注意力机制	95.6	0.312 5
双向 LSTM	90.9	0.421 7

由表 5 可见,注意力机制的引入使得双向 LSTM 网络故障预测模型的故障预测效果有了较大的提升。注意力机制能够进一步利用双向 LSTM 提取出的上下文特征信息,针对上下文信息中更为关键的高维特征进行重点提取^[34],以此提升故障预测模型的应用效能。

综上所述,基于注意力机制的双向 LSTM 轨道电路故障预测模型大幅提升了传统深度学习故障预测模型的故障预测正确率,达到了良好的故障预测效果。在实际应用中,电务段工作人员可以结合轨道电路微机监测系统采集到的数据并利用本模型对轨道电路进行故障预测,实现在故障发生之前提前介入,避免故障发生,达到“状态修”的目的,对于提高轨道电路可用性以及维护效率具有重要意义。

5 结论

(1)本文提出的基于注意力机制和双向 LSTM 网络的轨道电路预测模型能够准确预测轨道电路未来一段时间内的故障情况,在相关数据集上故障预测准确率可达 95.6%,且相比于经典深度学习模型,如 RNN、LSTM 等,具有显著优越性。

(2)本文提出的有关方法能够有效帮助电务段一

线工作人员提高轨道电路维护效率,并为轨道电路故障预测相关研究提供一种新思路。

参考文献:

- [1] 谢旭旭,戴胜华.基于深度学习的无绝缘轨道电路故障诊断研究[J].铁道学报,2020,42(6):79-85.
XIE Xuxu, DAI Shenghua. Fault Diagnosis of Jointless Track Circuit Based on Deep Learning[J]. Journal of the China Railway Society, 2020, 42(6): 79-85.
- [2] 于晓英,董煜,董昱.基于多方法证据融合的轨道电路故障诊断[J].铁道学报,2021,43(2):86-94.
YU Xiaoying, DONG Yu, DONG Yu. Fault Diagnosis of Track Circuit Based on Multi Method Evidence Fusion[J]. Journal of the China Railway Society, 2021, 43(2): 86-94.
- [3] 吴志鹏.基于决策树算法的 ZPW-2000A 轨道电路故障诊断[D].成都:西南交通大学,2016:1-2.
WU Zhipeng. Fault Diagnosis of ZPW-2000A Track Circuit Based on Decision Tree Algorithm [D]. Chengdu: Southwest Jiaotong University, 2016: 1-2.
- [4] 曹雲梦,边冰,张天奇.基于 BP 神经网络的轨道电路故障诊断[J].华北理工大学学报(自然科学版),2018,40(1):78-82.
CAO Yunmeng, BIAN Bing, ZHANG Tianqi. Track Circuit Fault Diagnosis Based BP Neural Network [J]. Journal of North China University of Science and Technology (Natural Science Edition), 2018, 40(1): 78-82.
- [5] 杨帆,王坚强,陈世然.贝叶斯网络在 ZPW-2000K 无绝缘轨道电路故障诊断中的应用[J].铁路通信信号工程技术,2016,13(6):73-75.
YANG Fan, WANG Jianqiang, CHEN Shiran. Application of Bayesian Network in ZPW-2000K Jointless Track Circuit Fault Diagnosis[J]. Railway Signalling & Communication Engineering, 2016, 13(6): 73-75.
- [6] 董昱,陈星.基于粗糙集和模糊认知图的 ZPW-2000 轨道电路故障诊断[J].铁道学报,2018,40(6):83-89.
DONG Yu, CHEN Xing. Intelligent Fault Diagnosis for ZPW-2000 Track Circuit Based on Rough Set Theory and Fuzzy Cognitive Map[J]. Journal of the China Railway Society, 2018, 40(6): 83-89.
- [7] 朱文博,王小敏.基于组合决策树的无绝缘轨道电路故障诊断方法研究[J].铁道学报,2018,40(7):74-79.
ZHU Wenbo, WANG Xiaomin. Research on Fault Diagnosis of Railway Jointless Track Circuit Based on Combinatorial Decision Tree [J]. Journal of the China Railway Society, 2018, 40(7): 74-79.
- [8] 黄斌.基于改进 GM(1,1) 和 SVM 的轨道电路故障最优组合预测模型研究[J].铁道科学与工程学报,2019,16(11):2852-2858.
HUANG Bin. Research on Fault Optimal Combination Prediction Model of ZPW-2000A Track Circuit Based on Improved Metabolic GM(1,1) and SVM[J]. Journal of Railway Science and Engineering, 2019, 16(11): 2852-2858.
- [9] HU L Q, HE C F, CAI Z Q, et al. Track Circuit Fault Prediction Method Based on Grey Theory and Expert System[J]. Journal of Visual Communication and Image Representation, 2019, 58: 37-45.
- [10] 孙浩洋.基于数据驱动的 ZPW-2000A 轨道电路故障预测方法的研究[D].兰州:兰州交通大学,2020:4-5.
SUN Haoyang. Research on Fault Prediction Method of ZPW-2000A Track Circuit Based on Data Drive [D]. Lanzhou: Lanzhou Jiaotong University, 2020: 4-5.
- [11] 康玄烨,赵林海,孟景辉,等.基于 LSTM 的轨道电路补偿电容故障数量预测[J].铁道学报,2021,43(1):94-99.
KANG Xuanye, ZHAO Linhai, MENG Jinghui, et al. LSTM-based Forecasting for Number of Faults of Track Circuit Compensation Capacitor [J]. Journal of the China Railway Society, 2021, 43(1): 94-99.
- [12] 夏荣斌,肖金山,吴永成.基于改进新陈代谢 GM(1,1) 的 ZPW-2000A 型轨道电路故障预测[J].兰州交通大学学报,2019,38(5):67-73.
XIA Rongbin, XIAO Jinshan, WU Yongcheng. Fault Prediction of ZPW-2000A Track Circuit Based on Improved Metabolic GM(1,1) [J]. Journal of Lanzhou Jiaotong University, 2019, 38(5): 67-73.
- [13] 中国铁路总公司. 普速铁路信号维护规则: TG/XH 101—2015[S]. 北京: 中国铁道出版社, 2015: 74-76.
China Railway. Regular-speed Railway Signal Maintenance Rules: TG/XH 101—2015 [S]. Beijing: China Railway Publishing House, 2015: 74-76.
- [14] 赵斌,张友鹏.基于傅里叶变换结合 Q-D 算法的轨道电路暂态分析[J].铁道学报,2016,38(3):78-83.
ZHAO Bin, ZHANG Youpeng. Transient Analysis of Track Circuits Based on FFT & Q-D Algorithm[J]. Journal of the China Railway Society, 2016, 38(3): 78-83.
- [15] 杨璟,王小敏,张文芳,等.基于 PMFCC-DTW 的轨道电路暂态故障诊断[J].铁道学报,2021,43(5):104-111.
YANG Jing, WANG Xiaomin, ZHANG Wenfang, et al. Transient Fault Diagnosis of Track Circuit Based on PMFCC-DTW[J]. Journal of the China Railway Society, 2021, 43(5): 104-111.
- [16] 王婷. ZPW-2000A 无绝缘轨道电路故障预测研究[D].成都:西南交通大学,2015:39-40.
WANG Ting. Research on Fault Prediction for ZPW-2000A Railway Jointless Track Circuits [D]. Chengdu: Southwest Jiaotong University, 2015: 39-40.
- [17] 周璐婕,党建武,王瑜鑫,等.基于 CNN-CSRF 组合模型的列控车载设备故障诊断[J].铁道学报,2020,42(11):94-101.
ZHOU Lujie, DANG Jianwu, WANG Yuxin, et al. Fault Diagnosis for On-board Equipment of Train Control System Based on CNN-CSRF Hybrid Model[J]. Journal of the China Railway Society, 2020, 42(11): 94-101.
- [18] HOCHREITER S, SCHMIDHUBER J. Long Short-term

- Memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
- [19] HOCHREITER S. Untersuchungen Zu Dynamischen Neuronalen Netzen [D]. München: Technische Universität München, 1991: 1-2.
- [20] BAHDANAU D, CHO K, BENGIO Y. Neural Machine Translation by Jointly Learning to Align and Translate[C]// International Conference on Learning Representation, San Diego: ICLR, 2015: 1-15.
- [21] GALASSI A, LIPPI M, TORRONI P. Attention in Natural Language Processing[J]. IEEE Transactions on Neural Networks and Learning Systems, 2021, 32(10): 4291-4308.
- [22] CHO K, COURVILLE A, BENGIO Y. Describing Multimedia Content Using Attention-based Encoder-Decoder Networks[J]. IEEE Transactions on Multimedia, 2015, 17(11): 1875-1886.
- [23] WANG F, TAX D M J. Survey on the Attention Based RNN Model and Its Applications in Computer Vision [DB/OL]. (2016-01-25) [2022-04-07]. <https://arxiv.org/abs/1601.06823>.
- [24] MNIH V, HEES N, GRAVES A, et al. Recurrent Models of Visual Attention [DB/OL]. (2014-06-24) [2022-04-07]. <https://arxiv.org/abs/1406.6247>.
- [25] MAHATO N K, DONG J, SONG C Y, et al. Electric Power System Transient Stability Assessment Based on Bi-LSTM Attention Mechanism [C]// 2021 6th Asia Conference on Power and Electrical Engineering. New York: IEEE, 2021: 777-782.
- [26] 刘益成, 于龙, 高仕斌, 等. 基于注意力机制的铁路巡检视频场景分类方法研究[J]. 铁道学报, 2021, 43(7): 95-101.
- LIU Yicheng, YU Long, GAO Shibin, et al. Research on Classification Method of Railway Inspection Video Scenes Based on Attention Mechanism [J]. Journal of the China Railway Society, 2021, 43(7): 95-101.
- [27] SRIVASTAVA N, HINTON G, KRIZHEVSKY A, et al. Dropout: a Simple Way to Prevent Neural Networks from Overfitting [J]. Journal of Machine Learning Research, 2014, 15(1): 1929-1958.
- [28] KINGMA D P, BA J. Adam: a Method for Stochastic Optimization [DB/OL]. (2017-01-30) [2022-04-07]. <https://arxiv.org/abs/1412.6980>.
- [29] LI L S, JAMIESON K, DESALVO G, et al. Hyperband: a Novel Bandit-based Approach to Hyperparameter Optimization [J]. Journal of Machine Learning Research, 2016, 18(1): 1-52.
- [30] FALKNER S, KLEIN A, HUTTER F. Practical Hyperparameter Optimization for Deep Learning [DB/OL]. (2018-02-13) [2022-04-07]. <https://openreview.net/forum?id=HJ-MudFkDf>.
- [31] SHI X J, DAI S H. Fault Prediction of Turnout Equipment Based on Double-layer Gated Recurrent Unit Neural Network [C]// 2021 IEEE International Intelligent Transportation Systems Conference. New York: IEEE, 2021: 2336-2341.
- [32] CHUNG J, GULCEHRE C, CHO K, et al. Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling [DB/OL]. (2014-12-11) [2022-04-07]. <https://arxiv.org/abs/1412.3555>.
- [33] SCHUSTER M, PALIWAL K K. Bidirectional Recurrent Neural Networks [J]. IEEE Transactions on Signal Processing, 1997, 45(11): 2673-2681.
- [34] CHAUDHARI S, POLATKAN G, RAMANATH R, et al. An Attentive Survey of Attention Models [DB/OL]. (2021-07-12) [2022-04-08]. <https://arxiv.org/abs/1904.02874>.

(责任编辑 陈宝安)