

文章编号: 1006-5911(2012)09-2012-06

# 支持向量回归粒子滤波器的故障预测方法

邓 森, 景 博, 周宏亮

(空军工程大学 航空航天工程学院, 陕西 西安 710038)

**摘 要:** 为了对系统进行故障预测, 针对粒子滤波在故障预测中出现的样本贫化与退化问题, 提出了一种支持向量回归粒子滤波器。采用支持向量回归方法建立粒子状态与其权值的非线性函数来估计粒子的连续后验概率密度模型。基于该模型进行重采样获得新的粒子集并更新各粒子的权重, 增加样本的多样性与有效性, 提高对故障的监控与预测能力。仿真结果表明, 该方法是可行的, 能够准确预报系统故障。

**关键词:** 粒子滤波器; 样本贫化; 粒子退化; 故障预测; 支持向量机

**中图分类号:** TP306 **文献标志码:** A

## Fault prediction method of improving particle filter with support vector regression

*DENG Sen, JING bo, ZHOU Hong-liang*

(Aeronautics and Astronautics Engineering College, Air Force Engineering University, Xi'an 710038, China)

**Abstract:** Aiming at the problem of particle degeneracy and sample impoverishment in fault prediction, an improving particle filter with support vector regression was proposed. The no-linear function of particle state and its weight was established by using support vector regression to estimate the particle's posterior probability density model. Based on this model, the new particle was obtained and weights of particles were updated by resampling, and the diversity and effectiveness of samples were improved. Thus the ability to control and predict the fault was raised. Simulation result demonstrated that the method was feasible and system fault could be predicted correctly.

**Key words:** particle filter; sample impoverishment; particle degeneracy; fault prediction; support vector machines

## 0 引言

故障预测技术是保证设备长期安全可靠运行的关键技术, 通过分析判断预测对象的结构特性、参数、环境条件以及历史数据, 可实现对设备未来运行状态的预报并指出故障发展的趋势。

粒子滤波算法是一种基于蒙特卡罗方法和递推贝叶斯估计的统计滤波方法, 被广泛地应用于目标跟踪<sup>[1-3]</sup>、语音增强<sup>[4]</sup>、故障诊断与预测<sup>[5-9]</sup>等领域。粒子滤波算法可以预测非线性、非高斯系统的故障和剩余寿命。粒子退化是粒子滤波中不可避免的现象, 解决方法主要是采取好的重要性密度函数和粒子重采样两大技术。重采样技术虽然在一定程度上

消除了退化现象, 却丧失了粒子多样性, 导致样本贫化。为解决传统粒子滤波在故障预测领域的缺点, 文献[6]提出权值优选粒子滤波器用于故障预测, 增加了样本的多样性, 但该方法需要更新大量备选粒子, 造成运算量增加。文献[7]提出一种强跟踪粒子滤波算法, 构造新的重要性密度函数, 以降低粒子退化与样本贫化, 在预测突变故障状态方面取得了良好的效果。文献[8]构建了高斯混合模型粒子滤波器对系统故障进行预测, 该方法采用高斯混合模型近似随机变量分布密度, 将状态变量后验分布迭代采样方法与数据驱动估计方法相结合以提高算法的预测能力, 但增加了算法的复杂程度。

本文基于支持向量机<sup>[10]</sup> (Support Vector Ma-

收稿日期: 2011-06-17; 修订日期: 2011-08-27。Received 17 June 2011; accepted 27 Aug. 2011.

基金项目: 航空科学基金资助项目(20101996012)。**Foundation item:** Project supported by the Aero-Science Foundation, China (No. 20101996012).

chines, SVM)在解决小样本回归问题时具有的速度快、精度高以及鲁棒性强等方面的优势,提出了支持向量回归(Support Vector Regression, SVR)粒子滤波器(Particle Filter, PF),简称 SVR-PF,用于系统的故障预测。采用 SVM 回归方法建立粒子状态与其权值的非线性回归函数,来估计粒子的连续后验概率密度模型。基于该模型进行重采样获得新的粒子集并更新各粒子的权重,增加粒子的多样性与有效性。最后将该方法与标准粒子滤波故障预测方法进行比较,进一步验证了方法的有效性与实时性。

## 1 故障预测问题的描述

设非线性系统可以表示为如下状态空间模型:

$$X_k = f(X_{k-1}, U_{k-1}) + w_k, \quad (1)$$

$$Y_k = h(X_k) + v_k. \quad (2)$$

式中:  $X_k, U_k$  与  $Y_k$  分别为  $k$  时刻系统的状态变量、输入变量和观测变量;  $w_k$  和  $v_k$  分别为系统噪声与量测噪声;  $f$  与  $h$  分别为系统的状态方程和量测方程。

对上述系统进行故障预测可转化为对系统状态变量的估计问题。根据指定的初始时刻到当前观测时刻  $k$  的观测序列  $\{Y_1, Y_2, \dots, Y_k\}$ , 通过故障预测算法求取未来  $k+p$  ( $p>0$ ) 时刻的系统状态变量  $X_{k+p}$  的状态估计值。

## 2 支持向量回归粒子滤波器

### 2.1 支持向量机回归算法

回归估计问题的实质是函数逼近问题, SVR 方法通过对样本数据的训练与学习, 建立输入与输出的非线性映射关系, 并将训练好的回归网络用于计算新样本的回归值。SVR 方法表述如下:

给定训练集  $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$ , 其中  $x_i \in R^n, y_i \in R, i=1, 2, \dots, n$ 。  $x_i$  是  $n$  维输入向量,  $y_i$  为输出向量, 通常情况下  $y_i$  可能混有噪声干扰。为获取非线性映射关系  $f$  使其满足:

$$f: R^n \rightarrow R. \quad (3)$$

根据 SVR 方法<sup>[9]</sup>, 通过对样本集  $T$  进行训练, 可以得到训练好的回归网络并获得回归估计函数  $f(x)$ ,

$$f(x) = \sum_{i=1}^n \alpha_i K(x, x_i) + b. \quad (4)$$

式中:  $K(\cdot)$  为支持向量机采用的核函数;  $\alpha_i$  和  $b$  为求得的回归参数。

### 2.2 支持向量回归粒子滤波器算法

为避免粒子退化对滤波器性能的影响, 最有效的方法是进行重采样来剔除小权值粒子, 而重采样又会使样本多样性丧失, 导致样本贫化。如果能够估计出准确的状态后验概率模型, 则再对模型进行重采样可以有效克服粒子的退化与贫化。

在粒子滤波过程中, 状态变量后验概率密度通常表现为非线性非高斯特性, 无法使用参数解析方法直接获取。SVR 是一种无参数回归技术, 基于支持向量机概率密度估计理论, 利用粒子及其相应的权值构造学习样本, 通过 SVR 拟合后验概率的离散分布模型, 基于该模型估计出连续分布概率模型, 然后在整个样本空间内进行重采样, 从而增加粒子的多样性。

假设粒子及其权值构成样本集  $\{(x_k^i, w_k^i)\}, i=1, \dots, N$ 。其中  $x_k^i$  表示从当前后验分布中采样得到的粒子,  $w_k^i$  为  $k$  时刻相应的概率密度值。基于训练样本集, 使用 SVR 方法构造  $k$  时刻的回归函数  $f_i(x)$ ,

$$f_i(x) = \sum_{i=1}^N \alpha_i K(x, x_k^i) + b_k. \quad (5)$$

将样本集  $x_k^i$  代入上式对其权值进行更新, 得到新的样本集  $\{(x_k^i, \hat{w}_k^i)\}, i=1, \dots, N$ , 从而将样本由离散的概率密度空间转化到连续空间。核函数  $K(\cdot)$  用来平滑估计后验密度函数, 以便更新每个粒子的权值。因此,  $k$  时刻的状态后验概率密度可以近似为

$$p(x_k | z_{1:k}) = \sum_{i=1}^N \hat{w}_k^i \delta(x_k - x_k^i). \quad (6)$$

在每次迭代过程中, SVR 粒子滤波器通过训练好的 SVM 网络更新各粒子的权值, 充分考虑了后验概率密度中相邻粒子之间的信息, 使后验概率分布中存在的奇异点与突变点不会在重采样过程中大量复制或剔除, 样本的多样性与有效性得到了保留。

设粒子近似服从双峰值(bimodal)分布, 粒子个数为 50。通过 SVR 方法更新权值后, 后验概率分布更接近于真实的后验概率, 如图 1 所示。

### 2.3 算法步骤

基于 SVR 的粒子滤波算法的流程如下:

**步骤 1 初始化。** 在  $k=0$  时刻, 依据初始分布  $p(x_0)$  抽取  $N$  个粒子构成初始粒子集  $\{x_0^i, 1/N | i=1, \dots, N\}$ , 置  $k=1$ 。

**步骤 2 重要性采样。** 根据先验分布采样得到




图1 SVR滤波器更新权值过程

预测样本  $x_k^i \sim p(x_k | x_{k-1}^i)$ ,  $i=1, \dots, N$ 。获得观测数据  $y_k$  后通过  $w_k^i = w_{k-1}^i p(y_k | x_k^i)$  计算样本的权值, 并进行归一化处理  $\hat{w}_k^i = w_k^i / \sum_{i=1}^N w_k^i$ 。

**步骤 3 SVR 更新权值。** 采用 2.2 节的方法对粒子集  $\{(x_k^i, w_k^i)\}$  进行训练, 得到优化的后验概率密度函数  $f_l(x_k^i)$ , 对样本更新权值得到新粒子集  $\{(x_k^i, \hat{w}_k^i)\}$ 。

**步骤 4 重采样。** 若  $N_{eff} < N_{th}$ , 则进行重采样。根据  $Pr(\hat{x}_k = x_k^i) = \hat{w}_k^i$  对粒子进行重采样并产生新的粒子集  $\hat{x}_k^i$ , 设定所有粒子的权值为  $1/N$ 。其中  $N_{eff}$  用来衡量粒子的退化程度, 该值越小粒子退化程度越高,  $N_{th}$  为进行重采样的门限阈值。

**步骤 5 输出状态估计值。** 若无重采样, 则  $\hat{x}_k \approx \sum_{i=1}^N x_k^i \hat{w}_k^i$ ; 若有重采样, 则  $\hat{x}_k \approx \sum_{i=1}^N (x_k^i \hat{w}_k^i) / N$ 。

**步骤 6** 设  $k=k+1$ , 返回步骤 2。

## 2.4 算法仿真及有效性验证

为验证 SVR 粒子滤波器的状态估计性能, 选取了文献[8]中的标准模型进行验证。该模型的状态方程与量测方程如式(7)和式(8)所示:

$$\begin{cases} x_k = f(x_{k-1}, k) + v_{k-1}, \\ y_k = \frac{x_k^2}{20} + n_k; \end{cases} \quad (7)$$

$$f(x_{k-1}, k) = \frac{x_{k-1}}{2} + \frac{25x_{k-1}}{1+x_k^2} + 8\cos(1.2k)。 \quad (8)$$

式中:  $v_k$  是均值为 0、方差  $Q_k=10$  的高斯噪声;  $n_k$  是均值为 0、方差  $R_k=1$  的高斯噪声。SVR 选择高斯核函数, 核参数  $\sigma=0.1$ , 标准化参数  $\gamma=100$ , 粒子初始概率密度分布服从  $N(0, 1)$ , 粒子个数  $N$  取 100, 最大迭代步数为 50。

图 2 为 SVR 粒子滤波器与基本粒子滤波器对上述模型的估计结果。图 3 为第 10 次迭代时 SVR 粒子滤波器与基本滤波器估计的后验概率密度函数。




图2 SVR-PF与PF的估计结果




图3 SVR-PF与PF估计的后验概率密度函数

定义估计均方误差的计算公式为:

$$RMES = \left[ \frac{1}{N} \sum_{n=1}^N (x_n - \bar{x}_n)^2 \right]^{1/2}. \quad (9)$$

分别使用以上两种滤波器对标准模型进行5次状态估计,求解估计均方根误差值(Root Mean Squared Error, RMSE)。结果如表1所示。

表1 均方根误差

滤波器模型	次数				
	1	2	3	4	5
SVR-PF	4.19	4.13	6.05	3.29	5.98
PF	5.01	4.37	6.89	3.97	6.23

由上述结果可知,SVR粒子滤波器比基本粒子滤波器具有更好的性能。由图3可知,通过SVR-PF估计的后验概率密度函数更加平滑,估计结果更接近粒子的真实后验概率分布。该方法在一定程度上避免了重采样过程中奇异点的大量复制,增加了样本的多样性,有效地避免了粒子退化。

### 3 故障预测算法设计

#### 3.1 粒子滤波器故障预测方法

利用粒子滤波器进行故障预测,其核心是对系统未来时刻的状态进行跟踪估计。在已知观测值 $y_{1:k}$ 的情况下,对系统进行 $p$ 步向前预测时,按照式(1)和式(2)所示的状态空间模型对粒子状态 $x_k$ 进行更新,获得粒子未来的 $p$ 个状态 $x_{k+1}, x_{k+2}, \dots, x_{k+p}$ ,并保证相应的权值 $w_k$ 不变。系统状态变量在 $k+p$ 时刻的后验概率密度可近似表示为:

$$p(x_{k+p} | y_{1:k}) \approx \sum_{i=1}^N w_k^i \delta(x_{k+p} - x_{k+p}^i). \quad (10)$$

假设系统的故障状态空间为 $\Phi$ ,则 $k+p$ 时刻相应的故障预测概率为:

$$Prob(x_{k+p}) = Prob(x_{k+p} \in \Phi) = \int_{x_{k+p} \in \Phi} p(x_{k+p} | y_{1:k}) dx_{k+p}. \quad (11)$$

$k+p$ 时刻状态变量的数学期望为:

$$E(x_{k+p}) = \int_{x_{k+p} \in \Phi} x_{k+p} Prob(x_{k+p}) dx_{k+p} = \sum_{i=1}^n x_{k+p}^i w_k^i. \quad (12)$$

设 $I(X)$ 为指标函数,当状态变量 $X \in \Phi$ 时, $I(X) = 1$ ,否则 $I(X) = 0$ 。因此故障预测概率表示为:

$$fault(p, k) = \sum_{i=1}^n w_k^i I(x_{k+p}^i | x_{k+j-1} \in \Phi),$$

$$j \in [1, p]. \quad (13)$$

考虑到预测精度与预测步数成反比,预测权值可表示为:

$$k_j = \frac{1}{j}, j \in [1, p]; \quad (14)$$

$$k_j^* = k_j / \sum_{j=1}^p k_j. \quad (15)$$

因此 $k_1 \in [p, k]$ 时刻的加权故障预测概率为

$$P - fault(k_1) = \sum_{j=1}^{k_1} fault(j, k_1 - j) k_j^*. \quad (16)$$

式中, $fault(j, k_1 - j)$ 通过式(13)进行计算,已知 $k_1 - j$ 时刻的系统状态预测 $k_1$ 时刻的状态。

#### 3.2 故障预测算法步骤

步骤1 按2.3节算法对系统状态进行估计。

步骤2 根据式(13)求解 $k$ 时刻 $p$ 步前向预测概率。

步骤3 根据式(14)~式(16)计算 $k_1$ 时刻的加权故障预测概率 $P - fault(k_1)$ 。

步骤4 当参数 $N_{eff} < N/3$ 时对样本进行重采样。

步骤5 令 $k = k + 1$ ,返回步骤2。

### 4 故障预测仿真实例与分析

#### 4.1 仿真实例

用本文算法对文献[8]中的三容水箱系统进行故障预测。该装置的主体是3个垂直放置的、大小一致的有机玻璃圆筒 $T_1, T_2$ 和 $T_3$ ,各圆筒的横截面积均为 $A$ ,3个圆筒由横截面积为 $S_n$ 的圆管相连接,在圆筒 $T_2$ 的下方有一个出水阀,流出的水收集到下方的有机玻璃水箱中,可重复使用,在 $T_1, T_2$ 和 $T_3$ 的下方各有一个截面积为 $S_1$ 的泄漏阀,一般情况下泄漏阀是关闭的。 $T_1$ 和 $T_2$ 中的液位 $h_1$ 和 $h_2$ 是通过两台水泵分别向 $T_1$ 和 $T_2$ 中注入流量为 $Q_1$ 和 $Q_2$ 的循环水来控制的。

通过对系统分析建立数学模型,选取系统的状态变量为三个水槽的液位 $h_1, h_2$ 和 $h_3$ ,三罐系统模型的有关参数见文献[5]。用四阶龙格库塔方法将系统离散化为如下方程:

$$\begin{aligned} x(k+1) &= x(k) + \Delta t A(x) + \Delta t B u(k) + w(k), \\ y(k) &= [x_1(k) \quad x_2(k) \quad x_3(k)]^T + v(k). \end{aligned} \quad (17)$$

式中:系统输入抽样间隔 $\Delta t = 0.054$  s,系统噪声 $w(k) \sim N(0, 2 \times 10^{-6})$ ,量测噪声 $v(k) \sim N(0, 1 \times$

$10^{-2}$ ), 仿真时间为  $200\Delta t$ , 状态变量的初始值  $x_1(0) = 0.4 \text{ m}$ ,  $x_2(0) = 0.3 \text{ m}$ ,  $x_3(0) = 0.35 \text{ m}$ , 参数  $az_1^0 = 0.5$ ,  $az_2^0 = 0.6$ ,  $az_3^0 = 0.5$ 。

SVR 选择高斯核函数, 核参数  $\sigma = 0.2$ , 标准化参数  $\gamma = 50$ , 粒子个数  $N = 100$ , 预测步数  $p = 5$ , 粒子初始概率密度分布服从  $N([0 \ 0 \ 0]^T, 10^{-2})$ 。图 4 为系统正常工作状态下 SVR 粒子滤波器的预测结果, 图 5 为 SVR-PF 与 PF 预测方法对状态变量  $x_2$  的误差曲线。

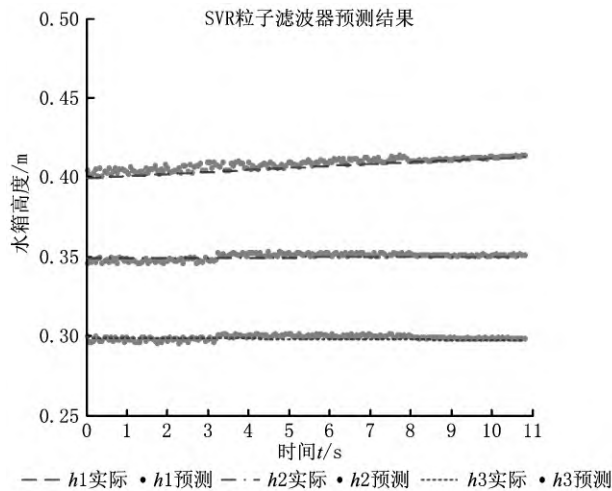


图4 正常状态下SVR-PF的预测结果




图5 SVR-PF与PF的估计误差曲线

定义系统故障状态

$$\Phi = \left\{ \left| \frac{h_k - h_k^0}{h_k^0} \right| \geq 0.1 \right\}, k = 1, 2, 3. \quad (18)$$

假设系统出现故障  $\Phi_1$  时, 参数  $az_2$  按以下方式发生变化:

$$az_2 = \begin{cases} 0.6, & 0 < k \leq 130; \\ az_2^0 + 0.06 \times (k - 20), & 130 < k \leq 150; \\ 4.2, & 150 < k \leq 200. \end{cases} \quad (19)$$

系统故障发生在  $130\Delta t \sim 150\Delta t$  之间, 图 6 为发生故障  $\Phi_1$  时 SVR-PF 的预测结果。设故障预测步数  $p = 5$ , 根据 3.1 节方法分别计算状态变量  $x_2$  在正常状态与  $\Phi_1$  故障状态时的故障预测概率, 如图 7 所示。

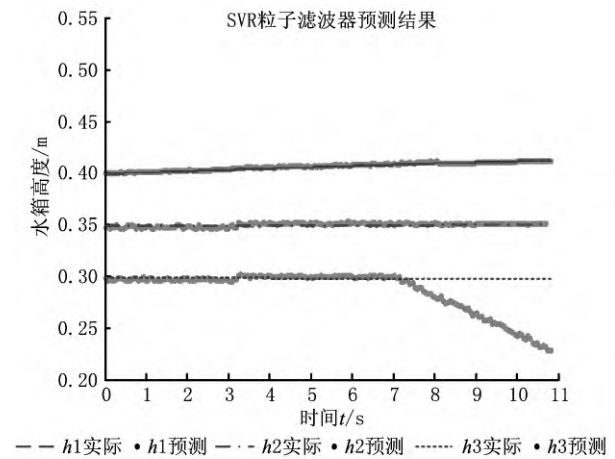


图6  $\Phi_1$ 故障状态下SVR-PF的预测结果




图7 基于SVR-PF的系统故障预测概率

在  $t \in [128\Delta t, 133\Delta t]$  的时间间隔内, 计算故障  $\Phi_1$  情况下状态变量  $x_2$   $p(p = 5)$  步向前故障预测概率如表 2 所示。

表 2 故障预测概率

液位与概率	t						
	128	129	130	131	132	133	134
$X_2$	0.273	0.272	0.271	0.269	0.268	0.268	0.267
Prob	0.56	0.44	0.86	0.71	0.99	0.91	1.00

## 4.2 仿真结果分析

由图4与图5可知,在正常工作情况下,SVR-PF可以较好地估计系统的状态变量。由于SVR对的后验概率密度函数有平滑作用,SVR-PF比PF的估计误差曲线更光滑,后验概率分布中存在的奇异点与突变点不会在重采样过程中大量复制或剔除,增加了粒子多样性。SVR-PF可以更好地估计出粒子的后验概率模型,且误差值相对较小,估计效果更好。

由图6、图7和表2可知,当系统发生故障时,采用SVR-PF预测系统的状态。在 $128\Delta t$ 时,系统状态变量 $x_2$ 的故障概率达到了0.56,并随时间逐渐增加。在 $134\Delta t$ 以后故障概率为1。SVR-PF能够准确预测系统的状态变化情况。

## 5 结束语

将SVR-PF用于系统的故障预测可以获得很好的效果。由于考虑到了后验概率密度中相邻粒子之间的信息,采用SVM回归方法建立的粒子连续后验概率密度模型更加逼近粒子真实的后验概率。通过SVR方法训练网络有效地避免了后验概率分布中存在的奇异点与突变点在重采样过程中大量复制或剔除,从而增加了样本多样性与有效性,提高了对故障的监控与预测能力。未来粒子滤波方法还需要进一步解决重要性密度函数的选择、重采样算法的选取以及粒子滤波算法收敛性证明等方面的问题,通过提升滤波器状态跟踪与估计的准确度与收敛速度,实现对故障的准确快速预测。

## 参考文献:

- [1] ZHA Yufei, BI Duyan. An adaptive particle filter for moving objects tracking[J]. Journal of Electronics and Information Technology, 2007, 29(1): 92-95 (in Chinese). [查宇飞, 毕笃彦. 一种基于粒子滤波的自适应运动目标跟踪方法[J]. 电子与信息学报, 2007, 29(1): 92-95.]
- [2] ZHU G, LIANG D, LIU Y, et al. Improving particle filter with support vector regression for efficient visual tracking [C]//Proceedings of IEEE International Conference on Image Process. Washington, D. C., USA: IEEE, 2005, 2: 422-425.
- [3] KABA OGLU N, CIRPAN H A. Wideband target tracking by using SVR-based sequential Monte Carlo method[J]. Signal Process, 2008, 88(11): 2804-2816.
- [4] ZHU Zhiyu. Speech enhancement technique based on Gaussian particle filter and time-varying autoregressive model[J]. Chinese Journal of Scientific Instrument, 2008, 29(9): 1903-1907 (in Chinese). [朱志宇. 基于高斯粒子滤波器和TVAR模型的语音增强技术[J]. 仪器仪表学报, 2008, 29(9): 1903-1907.]
- [5] ORCHARD M E, VACHTSEVANOS G J. A particle-filtering approach for on-line fault diagnosis and failure prognosis [J]. Transactions of the Institute of Measurement and Control, 2009, 31(3/4): 221-246.
- [6] ZHANG Qi, HU Changhua, QIAO Yukun, et al. Fault prediction algorithm based on weight selected particle filter[J]. System Engineering and Electronics, 2009, 31(1): 221-224 (in Chinese). [张琪, 胡昌华, 乔玉坤, 等. 基于权值选优粒子滤波器的故障预测算法[J]. 系统工程与电子技术, 2009, 31(1): 221-224.]
- [7] HU Changhua, ZHANG Qi, QIAO Yukun. A strong tracking particle filter with application to fault prediction[J]. Acta Automatica Sinica, 2008, 24(12): 1522-1527 (in Chinese). [胡昌华, 张琪, 乔玉坤. 强跟踪粒子滤波算法及其在故障预报中的应用[J]. 自动化学报, 2008, 34(12): 1522-1527.]
- [8] ZHANG Lei, LI Xingshan, YU Jinsong, et al. A fault prognostic algorithm based on Gaussian mixture model particle filter[J]. Acta Aeronautica et Astronautica Sinica, 2009, 30(2): 319-325 (in Chinese). [张磊, 李行善, 于劲松, 等. 一种基于高斯混合模型粒子滤波的故障预测算法[J]. 航空学报, 2009, 30(2): 319-325.]
- [9] ZHANG Lei, LI Xingshan, YU Jinsong, et al. fault prognostic algorithm based on dual-estimation and particle filter[J]. Journal of Beijing University of Aeronautics and Astronautics, 2008, 34(7): 798-801 (in Chinese). [张磊, 李行善, 于劲松, 等. 一种基于二元估计与粒子滤波的故障预测算法[J]. 北京航空航天大学学报, 2008, 34(7): 798-801.]
- [10] VAPNIK V N, GOLOWICH S, SMOLA A. Support vector method for function approximation, regression estimation and signal processing[C]//Proceedings of Advances in Neural Information Processing Systems. Boston, Mass., USA: MIT Press, 1997: 281-287.

## 作者简介:

邓 森(1986—),男,河南南阳人,博士研究生,研究方向:系统可靠性分析、故障诊断与预测方法等, E-mail: 425931056@qq.com;  
景 博(1965—),女,河北邯郸人,教授,博士生导师,研究方向:故障预测与健康管理、可测试性设计、传感器网络、数据融合。  
周宏亮(1966—),男,河南洛阳人,博士研究生,高级工程师,研究方向:故障预测与管理、可测试性设计、数据融合。