

基于深度学习算法的电气控制系统故障诊断与预测研究

姬光楠

(中航光电科技股份有限公司)

摘要: 电气控制系统是现代工业和日常生活中不可或缺的组成部分, 它们的稳定运行对保障设备安全 and 提高效率至关重要。然而, 由于系统复杂性和环境的不确定性, 故障的发生在所难免。**传统的故障排查方法往往依赖于专家知识和经验**, 在处理复杂系统时显得力不从心。近年来, 深度学习算法凭借其强大的**特征学习和模式识别能力**, 在故障诊断领域展现出了巨大的潜力。本文系统阐述了电气控制系统故障排查的基本流程, 详细介绍了基于深度学习算法的故障诊断与预测方法, 包括**深度学习模型、深度置信网络、卷积神经网络的应用**, 并通过**实际测试验证**了这些方法在故障诊断中的有效性和实用性。

关键词: 深度学习算法; 电气控制; 故障诊断; 预测

0 引言

深度学习作为人工智能领域的一个重要分支, 通过其强大的数据处理和特征提取能力, 为电气控制系统的故障诊断和预测提供了新的解决方案。特别是深度学习算法能够从**大量数据中自动提取关键特征**, 这对于处理**复杂系统中的非线性、非平稳信号**特别有效。诸如**深度信念网络、卷积神经网络、循环神经网络**等深度学习模型已被证明在识别和分类电气系统故障模式方面具有显著优势。这些模型能够通过**学习历史故障数据, 提前识别系统可能出现的异常状态**, 从而实现故障的早期预警和预测。

1 电气控制系统故障排查基本流程

电气控制系统是现代工业自动化的核心, 其稳定和高效的运行对生产安全与经济效益具有直接影响。系统的故障排查流程是保障其正常运行的关键环节, 这一过程涉及对系统的全面理解、故障的准确检测以及有效的故障排除方法。对电气控制系统的功能和结构进行全面的分析和理解是故障排查的前提。这包括了解系统的设计原理、工作机制以及各组件之间的相互作用。再运用传感器和监控设备对系统的关键参数进行实时监控, 如电流、电压、温度等, 以便于及时发现系统的异常指标。在检测到异常信号后, 应用故障诊断方法来确定故障的性质和位置。**传统的故障诊断方法, 如基于时域、频域分析的信号处理技术**, 虽然在某些情况下有效, 但在**处理复杂系统时存在局限**

性, 而**深度学习算法**, 在这一领域展现出了卓越的潜力。通过**对历史数据的学习**, 这些算法**能够从大量复杂的数据中提取出关键特征**, 从而实现对故障模式的准确判别。

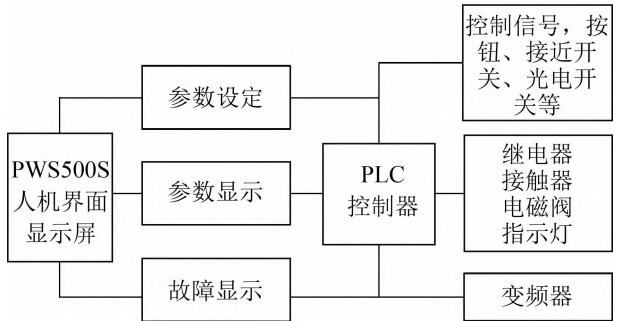


图 电气控制系统故障排查基本流程

2 基于深度学习算法的电气控制系统故障诊断与预测

2.1 深度学习模型

深度学习模型, 特别是**卷积神经网络 (CNN)**, 因其出色的**特征提取能力和自动学习复杂模式的能力**, 在电气系统故障检测和分类中显示出巨大潜力^[1]。考虑电气控制系统的输入数据 X , 这些数据可以是电流、电压、温度等多种传感器读数的时间序列。**CNN 模型通过多层结构来提取这些输入数据中的重要特征**, 首先是卷积层 (Convolutional Layer), 其基本操作可以表示为:

$$F_{ij} = \sum_m \sum_n X_{m,n} \cdot K_{i,j}(m,n) \quad (1)$$

式中, F_{ij} 为卷积层输出的特征图在位置 (i,j) 的值; $X_{m,n}$ 为输入数据; 在位置 (m,n) 的值; $K_{i,j}(m,n)$ 为卷积核的权重。

然后是激活层, 通常使用 **ReLU 函数**, 其表达式为:

$$g(x) = \max(0, x) \quad (2)$$

ReLU 函数对卷积层的输出应用非线性激活, 提高了模型处理非线性数据的能力。

模型中通常包含池化层 (Pooling Layer), 它的作用是降低特征图的空间尺寸, 从而减少计算量和避免过拟合。一个常见的池化操作是最大池化, 可以表示为:

$$P_{ij} = \max_{m,n \in \text{Window}} F_{i+m,j+n} \quad (3)$$

式中, P_{ij} 为池化层输出的值; $F_{i+m,j+n}$ 为卷积层输出特征图中的值。

在多个卷积、激活和池化层之后, 网络通常包含一到多个全连接层 (Fully Connected Layer), 其在处理序列化的特征数据时表现出强大的能力。全连接层的计算可以表示为:

$$Y_k = \sum_i W_{ki} \cdot H_i + b_k \quad (4)$$

式中, Y_k 为全连接层的输出; W_{ki} 为权重; H_i 为前一层的输出; b_k 为偏置项。

最后, 使用损失函数 (如交叉熵) 来训练网络, 优化模型的权重和偏置, 以实现电气系统故障模式的高效识别。损失函数的一个常见形式是:

$$L(\theta) = - \sum_i y_i \log(p_i(\theta)) \quad (5)$$

式中, y_i 为正则化参数; $p_i(\theta)$ 为模型参数; P_i 为预测的概率; θ 为模型的参数集合。

此外, 为了提升模型在实时监测中的性能, 采用适当的正则化技术 (如 **L2 正则化**) 和优化算法 (例如 **Adam 或 SGD**) 是至关重要的。L2 正则化通过在损失函数中添加一个正则项来实现, 以减少模型复杂度并防止过拟合, 其表达式为:

$$L_{\text{reg}}(\theta) = L(\theta) + \lambda \sum_k \theta_k^2 \quad (6)$$

式中, λ 为正则化参数; θ_k^2 为模型参数。

优化算法, 如 Adam, 通过迭代更新模型参数来最小化损失函数, 其更新规则为:

$$\theta_{i+1} = \theta_i - \eta \cdot \hat{m}_i / (\sqrt{\hat{v}_i} + \epsilon) \quad (7)$$

式中, θ_i, θ_{i+1} 分别为在迭代 i 和 $i+1$ 时的模型参数; η 为学习率; \hat{m}_i, \hat{v}_i 分别为一阶和二阶矩的估计; ϵ 为一个小的常数以避免除以零。通过对深度学习模型的精确设计和参数优化, 可以大幅提高电气控制系统

故障诊断与预测的准确性和效率。

2.2 深度置信网络

深度置信网络作为一种高效的生成式模型, 通过多层非线性变换, 能够捕捉复杂数据中的高级抽象特征, 对于解析电气系统中的复杂模式具有显著优势^[2]。深度置信网络由多个受限玻尔兹曼机堆叠而成, 其能量函数定义为:

$$E(v, h) = - \sum_{i \in \text{visible}} \sum_{j \in \text{hidden}} v_i w_{ij} h_j - \sum_{i \in \text{visible}} a_i v_i - \sum_{j \in \text{hidden}} b_j h_j \quad (8)$$

式中, v, h 分别为可见层和隐藏层的节点状态, w_{ij} 为两层之间的权重; a_i 和 b_j 为偏置项。

给定可见层的状态, 隐藏层节点的激活概率为:

$$p(h_j = 1 | v) = \sigma(\sum_i w_{ij} v_i + b_j) \quad (9)$$

式中, σ 为 **sigmoid 激活函数**。类似地, 给定隐藏层的状态, 可见层节点的激活概率为:

$$p(v_i = 1 | h) = \sigma(\sum_j w_{ij} h_j + a_i) \quad (10)$$

通过对 RBM 的训练, 可以学习到数据中的特征表示, 这是通过最大化数据的对数似然来实现的。

在 DBN 中, 每个 RBM 层的隐藏层输出被用作上一层的输入。经过逐层预训练后, 整个网络可以通过反向传播进行微调, 以进一步优化参数。在电气控制系统故障诊断的应用中, DBN 可以通过学习电气系统运行数据的复杂模式来识别异常状态, 进而实现故障的早期预测。

2.3 卷积神经网络

CNN 作为一种深度学习架构, 因其在图像处理、序列数据处理和特征识别方面的卓越能力, 在电气控制系统故障诊断中扮演着关键角色^[3]。CNN 通过层叠的卷积层、激活层和池化层自动学习和提取数据特征, 适合于处理电气系统运行数据中的空间和时间模式^[4]。

考虑一个典型的 CNN, 其首个卷积层可以表示为:

$$F_{ij}^k = \sigma(b_k + \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} W_{mn}^k \cdot X_{i+m,j+n}) \quad (11)$$

式中, F_{ij}^k 为第 k 个特征图在位置 (i,j) 的输出; σ 为激活函数 (通常为 ReLU 函数); b_k 为偏置项; W_{mn}^k 为卷积核的权重; W_{mn}^k 为输入数据在 $(i+m, j+n)$ 位置的值; M 和 N 为卷积核的尺寸。

接下来的池化层 (例如最大池化) 用于降低特征维度并提高模型的不变性。池化操作可以表述为:

$$P_{ij}^k = \max_{m,n \in \text{Window}} F_{i+m,j+n}^k \quad (12)$$

式中, P_{ij}^k 为池化层在位置 (i,j) 的输出; \max 表示在指定窗口内取最大值。

CNN 的卷积层和池化层交替出现，逐渐构成了一个深度网络，最终通过全连接层和 softmax 层进行分类。全连接层的计算为：

$$Y_k = \sigma(b_k + \sum_i W_{ki} \cdot H_i) \quad (13)$$

式中， Y_k 为全连接层的输出； W_{ki} 为权重； H_i 为前一层的输出； b_k 为偏置项。

softmax 层用于多类别的故障诊断，其输出为：

$$p(y = k | X) = \frac{\exp(z_k)}{\sum_l \exp(z_l)} \quad (14)$$

式中， $p(y = k | X)$ 为给定输入 X 时预测为类别 k 的概率； z_k 为全连接层的输出； l 为类别的总数。

为了训练 CNN，通常采用反向传播算法和梯度下降法来最小化损失函数，例如交叉熵损失函数，其公式为：

$$L(\theta) = - \sum_i \sum_k y_{ik} \log(p(y = k | x_i; \theta)) \quad (15)$$

式中， θ 为网络参数； y_{ik} 为第 i 个样本属于类别 k 的真实标签； $p(y = k | x_i; \theta)$ 为模型预测的概率。

在电气控制系统中，CNN 的应用不仅限于故障诊断，还包括预测性维护，即通过持续监控和分析系统的运行数据，预测潜在的故障和性能下降。

3 故障诊断系统测试

本研究采用的数据集是专门为电气控制系统故障诊断与预测而设计的。这些数据集主要由实测数据构成，采集自不同的电气控制系统，包括工业环境中的多种设备。为了保证研究的广泛适用性和准确性，这些数据经过了严格的筛选和处理，确保其质量和代表性。部分数据也来自于网络上公开的可靠数据集，这些公开数据集通常由电气系统运行和维护的专业机构发布，保证了数据的真实性和有效性。在使用数据集的过程中，将数据分为两部分，一部分用于模型的训练，另一部分用于测试。大约 80% 的数据用于训练深度学习模型，以确保模型能够学习到电气系统运行中的各种正常和异常模式。剩余 20% 的数据用于测试，以评估模型在实际应用中的性能和准确性^[5]。这种划分方式有助于平衡模型训练和验证的需求，确保模型能够有效地应对各种实际情况。测试的主要指标包括准确率、召回率、精确度和 F1 分数。准确率衡量的是模型预测正确的比例，召回率评估的是模型能够正确识别故障情况的比例，精确度则是预测为故障的情况中实际为故障的比例，而 F1 分数是精确度和召回率的调和平均，用于综合评价模型的性能。故障诊断系统测试结果见下表。

表 故障诊断系统测试结果

数据类型	数据量	准确率 /%	召回率 /%	精确度 /%	F1 分数 /%
电流	1000000	95.67	94.32	96.21	95.26
电压	1000000	96.54	95.48	97.35	96.41
温度	1000000	94.73	93.89	95.62	94.75
湿度	1000000	93.58	92.47	94.66	93.56
信噪比	1000000	94.82	93.95	95.7	94.82

从这些结果可以看出，模型在各个数据类型上都表现出了较高的准确率和 F1 分数，特别是在电压数据上，准确率和 F1 分数均超过了 96%。这表明该模型对于电气控制系统中的故障诊断具有较高的准确性和可靠性。另外，召回率和精确度在各个数据类型上也保持了较高水平，表明模型能够有效地识别大部分的故障情况，这些结果整体上反映了该深度学习模型在电气控制系统故障诊断方面的优越性能。

4 结束语

基于深度学习算法的电气控制系统故障诊断与预测技术，不仅具有重要的理论价值，而且对提高电气控制系统的稳定性和安全性，减少意外停机时间，降低维修成本，以及提升整体经济效益具有显著的实际意义。具体而言，此研究旨在探索深度学习算法在电气控制系统故障检测、诊断和预测方面的应用潜力，包括但不限于开发高效的故障特征提取方法、构建准确的故障预测模型，以及实现复杂电气系统故障模式的自动识别与分类。通过对深度学习算法在电气控制系统中的应用进行深入研究，不仅可以推动电气工程领域的技术进步，还能为相关经济决策提供数据支持和智能分析工具，从而促进工业自动化和智能制造的发展。

参考文献

- [1] 余萍，曹洁. 深度学习在故障诊断与预测中的应用 [J]. 计算机工程与应用，2020，56 (3)：1-18.
- [2] 赵书涛，徐晚会，尹子会，等. 基于深度学习断路器储能机构故障诊断方法研究 [J]. 高压电器，2022，58 (10)：25-32.
- [3] 王景阳，王有杰，孙守瑄. 基于深度域对抗迁移学习的提升机健康状态诊断系统 [J]. 能源与环保，2023，45 (11)：225-231.
- [4] 周伟波，潘虹. 基于改进深度学习的海上风电机组齿轮故障预测方法 [J]. 供用电，2022，39 (6)：83-91.
- [5] 齐振兴，张倩，丁津津，等. 基于特征迁移和深度学习的配电网故障定位 [J]. 科学技术与工程，2022，22 (33)：14752-14758.

(收稿日期：2024-01-24)