

公路工程
Highway Engineering
ISSN 1674-0610, CN 43-1481/U

《公路工程》网络首发论文

题目：基于孪生长短时神经网络的高速公路机电系统故障预测
作者：曹佳宝，彭巍，杨飞，刘洋，赵恺
收稿日期：2023-12-18
网络首发日期：2024-10-09
引用格式：曹佳宝，彭巍，杨飞，刘洋，赵恺. 基于孪生长短时神经网络的高速公路机电系统故障预测[J/OL]. 公路工程.
<https://link.cnki.net/urlid/43.1481.U.20241008.1619.002>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于孪生长短时神经网络的高速公路机电系统故障预测

曹佳宝^{1,2}, 彭巍^{1,2}, 杨飞^{1,2}, 刘洋^{1,2}, 赵恺^{1,2}

(1. 湖南省交通科学研究院有限公司, 湖南 长沙 410014; 2. 交通建设工程湖南省重点实验室, 湖南 长沙 410015)

[摘 要] 对神经网络在高速公路机电系统故障预测中的应用进行了研究。报告了当前基于电力系统参数的故障状态识别研究现状及痛点, 阐述了高速公路电力参数监控系统采集数据的对象、类型及处理方法, 针对机电系统真实的故障样本少的问题, 提出了基于孪生长短时神经网络 (SLSTM) 的机电系统故障预测模型, 采用窗口时间的采样方法将故障预测问题转变为故障分类问题, 并进行了试验验证。试验结果表明, 在小样本数据集下, 孪生长短时神经网络 (SLSTM) 相比单一的长短时神经网络 (LSTM) 对于机电系统故障预测有更好的效果, 准确率可以达到 92.74%, 对机电系统故障预警有重要意义。

[关键词] 高速公路; 机电系统; 孪生神经网络; 长短时神经网络; 故障预测

[中图分类号] U495 **[文献标志码]** A

Fault Prediction of Electromechanical Systems Based on Siamese Long Short-Term Neural Networks

CAO Jiabao^{1,2}, PENG Wei^{1,2}, YANG Fei^{1,2}, LIU Yang^{1,2}, ZHAO Kai^{1,2}

(1. Hunan Communications Research Institute Co., Ltd., Changsha, Hunan 410014, China; 2. Hunan Provincial Key Laboratory of Traffic Construction Engineering, Changsha, Hunan 410015, China)

[Abstract] This study investigates the application of neural networks in forecasting highway electromechanical system faults. Reported the current research status and pain points of fault state recognition based on power system parameters. It elucidates the object, types, and handling methods of data collected by the highway power parameter monitoring system. Addressing the scarcity of real fault samples in electromechanical systems, it proposes a predictive model using Siamese Long Short-Term Memory (SLSTM) neural networks. Employing windowed time sampling transforms the fault prediction into a classification issue and undergoes experimental validation. The experimental outcomes demonstrate that the SLSTM outperforms standalone LSTM models in electromechanical fault prediction on small sample datasets, achieving an accuracy of 92.74%. This holds significant importance for electromechanical system fault alerts.

[Key words] highway; electromechanical system; siamese neural network; long short-term neural network; fault prediction

0 引言

随着高速公路建设的不断发展, 高速公路在役机电设备数量日益庞大, 机电系统的状态关系到高速公路的运行安全和管理效率, 因此, 如何高效实时预测高速公路机电系统故障是高速公路管理者非常关心的问题。目前机电设备故障识别的相关研究主要基于机电设备参数、机电设备特性曲线^[1-4], 面向的设备类型较为具体。针对更宏观的机电系统回路状态估计, 相关学者提出基于电力系统参数的故障状态识别是通过对机电系统电气量参数进行数据分析^[5]。人工神经网络在复杂特征提取和迁移学习方面具有良好性能, 常被应用到系统故障预测中^[6-7]。2017 年, Zhang 等^[8]提出了基于深度学习的多变量异构时间序列数据的故障预测架构, 并采用成本敏感公式来预测分类任务。2018 年, Cenek 等^[9]基于多个能源模块, 构建了用于农村微电网电力负荷预测的神经网络模型。2019 年, Kong 等^[10]基于住宅电表数据, 提出了短期住宅负荷预测的 LSTM 神经网络模型。2020 年, Gao 等^[11]提出用于云数据中心系统故障预测的双向长短时记忆网络模型, 试验结果表明其性能优于 LSTM 网络模型。2021 年, Georgouloupoulos 等^[12]探讨了采用机器学习与深度学习识别系统故障的问题, 提出了基于深度学习的机电系统故障预测的应用前景。钱子晨^[13]提出分两步实现机电系统故障预测, 首先采用栈式稀疏自编码器进行机电系统故障检测, 接着采用深层稀疏长短时融合网络进行故障分类。2022 年, Azhar M 等^[14]回顾了近年来应用于机电系统预防性养护的深度学习模型, 现 AE、LSTM 和 CNN 是最常用的, 但缺乏深度学习融合模型的研究。

根据现有研究总结可知, 深度学习对电气量参数的时序变化特征有较好的提取性能^[15], 但在故障预测领

[收稿日期] 2023-12-18

[基金项目] 湖南省交通运输厅科技进步与创新计划项目 (202303-4-2); 湖南省科技人才托举工程专项 (2022TJ-03);

[作者简介] 曹佳宝 (1988—), 男, 陕西西安人, 高级工程师, 主要从事智慧交通、智慧建筑方面研究。

域，针对深度学习融合模型的研究还不够，同时，由于机电系统故障样本量较小，不利于深度学习的大规模训练。基于此，本文以高速公路电力参数监控系统数据为依托，创新地提出一种基于孪生长短时神经网络的机电系统故障预测模型及方法。根据机电系统故障的时序数据、小样本的特点，采用对时间序列较为敏感的LSTM网络，可以有效提取出时序特征，并采用在处理小样本数据方面有较好效果的孪生神经网络，对样本对的时序数据特征进行比较分析，实现机电系统状态判别，为高速公路机电系统状态感知提供一种高效、可靠的解决方式。

1 高速公路电力参数监控系统

高速公路机电系统主要包括监控、通风、照明、供配电、消防检测、紧急电话和广播等多个系统。为集中监测与控制高速公路机电系统的工作状态，高速公路电力参数监控系统可以通过各个变电站的设备监控单元、计量仪表，采用轮询和主动上报两种方式采集设备及回路的模拟信号、数字信号、状态信号，采集对象、采集频率及主要电力参数见表 1。根据状态信号及真实机电系统的故障维护记录，将电气量数据反映的系统故障类型分为电流过载和电压过载两类，分别用 $F = 1$ 和 $F = 2$ 表示，正常状态设为 $F = 0$ ，每个时刻对应一个特征向量和一个系统状态。不同系统回路设备数量不同，采集的特征向量在维度上存在一定区别，在时间维度上，电力参数监控系统每小时记录一次数据，各设备的电力参数在时间维度上堆叠形成高速公路机电系统电力参数矩阵，如某高速公路机电系统的电力参数特征维度为 N ，记录了 T 个时刻的数据，则形成的电力参数矩阵为 (N,T) 。

表 1 高速公路电力监控系统数据采集
Table1 Data acquisition of expressway electromechanical system

采集对象	主要电力参数			采集频率
	模拟信号	数字信号	状态信号	
进出线、UPS 电源、外场照明回路、低压总开关回路、综合继保设备等	有功功率(P)、无功功率(Q)、视在功率(S)、电流(I)、电压(U)、功率因数($\cos\phi$)	电网频率(f)、脉冲电度	开关量、电源停电信号、通道故障信号、柴油发电机组运行信号等	1 次/小时

为了解数据特征规律，以某高速公路机电系统三年半时间内采集的数据为例进行的可视化分析，图 1 为该高速某回路低压总进线的 U_{ab} 、 U_{bc} 、 U_{ca} 、 I_a 、 I_b 、 I_c 、 P 、 Q 、 \cos 、 Hz 、电度 1、电度 2 等电力参数时序图，并以散点标注了系统故障发生时刻。由图 1 可知，各特征在时间序列上波动起伏较大，特征之间量纲差异大，部分电力参数在时序上始终不变。为将原始的高速公路电力参数监控系统数据应用于故障预测，本文进行了数据清洗，采用 min-max Normalization 的方法将数值归一化，并采用 Z-score Normalization 将数据标准化，使其映射至 $[0, 1]$ 区间内符合标准正态分布无量纲集，以避免量纲不同、数据分布不均造成数据之间权重差异过大。同时，将在时序上始终不变的电力参数剔除，以减少无效信息的对模型的干扰。

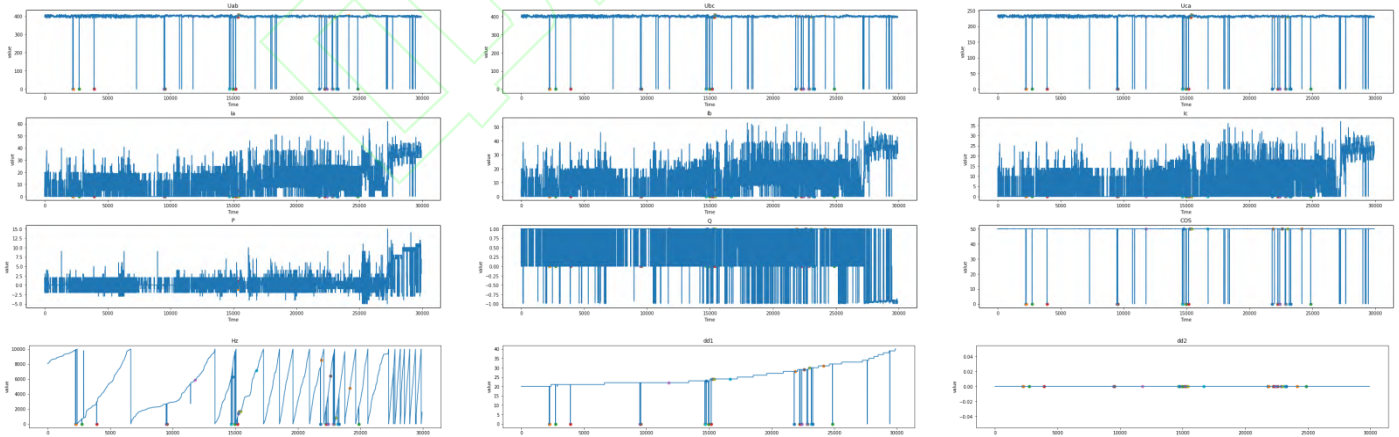


图 1 某回路低压总进线部分电力参数时序图
Figure 1 Time series plot of electrical parameters of low-voltage main inlet line of a certain loop

2 长短时神经网络

循环神经网络通过从序列中提取的前向信息不断更新权值，使后序序列受到前序序列的影响，从而实现序列特征的提取并取得良好的预测结果，其单元展开图如图 2 所示。长短时神经网络^[16]是循环神经网络的一种，采用输入门、遗忘门、输出门控制隐状态与核状态的更新和传递，使得网络具有遗忘的特性，从而能更好地学习到长期和短期的序列特征，其循环单元如图 3 所示。




图 2 循环网络单元展开图
Figure 2 Recurrent neural network unit expansion diagram




图 3 LSTM 的循环单元
Figure 3 Recurrent unit of LSTM

3 孪生神经网络

孪生神经网络 (Siamese network) 与普通的神经网络不同，其本质是一种深度度量学习方法，通过对一组样本的特征做相似度度量，得到输出结果，因此，在人脸识别、目标跟踪、语义相似度分析等领域有着良好的应用效果。

孪生神经网络通常由两个权值共享的子网络组成，本文选用将 LSTM 作为其子网络，如图 4 所示。输入也是两个不同样本的特征，通过对子网络提取后的两个样本向量进行距离度量，判定两个样本的相似度，完成网络权值训练，接着用已知类别样本和未知类别样本组合输入，实现未知样本分类^[17-18]。由于输入的是一个样本对，样本之间的组合关系使得可以用于模型训练的数据增加，孪生神经网络对于小样本数据的学习能力较强。机电系统故障样本非常少，正负样本明显不平衡，因此，采用孪生神经网络可以一定程度上解决此问题。

孪生神经网络的损失函数是一种基于向量间距离度量的对比损失，即相同类别的特征向量间距离较小，不同类别的特征向量间距离较大。其具体定义如下：

$$loss = \frac{1}{2N} \sum_{n=1}^N [Yd^2 + (1 - Y)\max(0, m - d)^2]$$

式中： Y 表明两个输入样本为同类别， $1 - Y$ 表明两个输入样本为不同类别， m 为人工设定的不同类别间的距离阈值， d 为两样本经网络提取后的特征向量之间的欧氏距离。

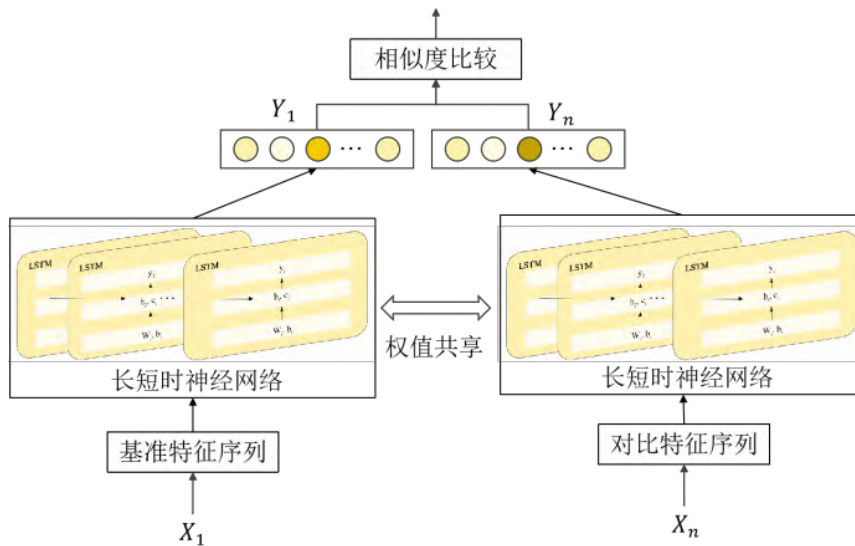


图 4 孪生长短时神经网络结构图
Figure 4 Siamese Long Short-Term Neural networks

4 机电系统故障预测模型

4.1 数据集

本节以某高速公路机电系统的电力参数监控系统数据为例，评估长短时神经网络以及孪生长短时神经网络在机电系统故障预测上的效果。该数据集的时间范围为 2019 年 1 月 1 日至 2022 年 5 月 31 日，共计 1247 天，29928 小时，每一个小时记录一次各设备的电压、电流、功率、频率等数据，得到一个 305×29929 的信息矩阵，部分原始参数数据见表 2。根据该机电系统的维修记录，在数据采集的时间范围内，故障时间总数为 1053，刨除故障维修时间，从正常状态转变为故障状态的时间节点数为 308，其中过电流故障有 213 次，过电压故障有 95 次，分别设为 $F = 1$ 和 $F = 2$ ，正常状态设为 $F = 0$ 。本文所构建的故障预测模型，是基于前序时间序列预测下一时刻的状态，包括正常、过电压、过电流三种状态类型，本文网络模型预算法均在 Python3.6、Jupyter Notebook 环境即 tensorflow2 算法库中编译实现，计算机配置为 Intel(R) Core™ i7-10710 CPU 1.10GHz 1.61GHz, RAM 为 32GB。

表 2 高速公路机电系统电气量参数部分原始数据

DATA LOGGING	D0. Dot00	D1. Dot00	D2. Dot00	D3. Dot00	D4. Dot00	D5. Dot00	D6. Dot00
MAINLINE. 10kV_OL1_IA	0.01	0	0	0	0.02	0.01	0
MAINLINE. 10kV_OL1_IB	0.02	0	0	0.01	0.02	0.01	0
MAINLINE. 10kV_OL1_IC	0	0	0.02	0.01	0.01	0	0
MAINLINE. 10kV_OL1_IAM	0.64	0.65	0.5	0.57	0.51	0.49	0.49
MAINLINE. 10kV_OL1_IBM	0.7	0.66	0.58	0.65	0.61	0.58	0.57
MAINLINE. 10kV_OL1_3U0	0	0	0	0	0	0	0
MAINLINE. LP8-1_SB_Ua	230.300003	229.899994	229.199997	230	230.899994	231	230.199997
MAINLINE. LP8-1_SB_Ub	228.899994	227.699997	227.600006	227.800003	228.800003	228.399994	227.800003
MAINLINE. LP8-1_SB_Uc	230.100006	230.100006	229.699997	230.199997	230.5	230.5	230.100006
MAINLINE. LP8-1_SB_Uab	397.600006	396.200012	395.5	396.399994	398.100006	397.799988	396.600006
MAINLINE. LP8-1_SB_Ubc	397.5	396.399994	396	396.600006	397.700012	397.399994	396.5
MAINLINE. LP8-1_SB_Uca	398.700012	398.299988	397.399994	398.5	399.5	399.600006	398.600006

4.2 样本时间窗口

受到计算机视觉方法的启发，将训练集中时间序列的连续变量划分为有限数量的时间序列单元切片，并与系统状态类别结合，形成可用于分类任务的样本^[19-20]。把包含 t 个连续时间步的单元作为观测窗口 X_t ，观测窗口的最后一个时间步作为预警时间点，在预警时间点之后 k 个时间步内发生的事件 Y_t 作为该单元的分类，这样就将事件预测问题转换为了经典的分类问题。本文将故障发生前的一个小时作为故障预警时间点，并选

取故障预警时间点之前的窗口时间 t 作为故障状态时间序列样本，如图 5 所示。正常状态时间序列样本同样基于窗口时间 t 划分，由于机电系统的正常运行状态较多，正常样本的采样范围较大。样本时间窗口的选取直接影响模型的输入数据特征， t 过大会使得模型的输入数据中存在较多与故障发生无关的信息，导致重要特征被忽略， t 过小可能导致故障样本的代表性特征未被涵盖，使神经网络模型难以捕捉到变量之间的依赖关系。本文通过试验比选来确定最优的窗口时间 t 。




图 5 样本时间窗口示意图
Figure 5 Sample time window diagram

4.3 模型构建

本文所提出的孪生长短时神经网络的子网络为双层 LSTM，其中第一层由 64 个 LSTM 的循环单元组成，每个时刻的结果向上输出，第二层由 64 个 LSTM 循环单元组成，只有最后一个时刻的结果向上输出，将两个子网络的输出结果进行距离度量得到孪生网络的输出结果。模型的初始学习率设为 0.0001，优化器选用 Nadam，模型采用批数据标准化的方法，batch_size 设为 32。

4.4 试验分析

在数据集上以一定的窗口时间 t 进行采样，并匹配该单元对应的系统状态类别，得到可以用于模型训练和测试电气量信息矩阵样本，表示为 $\{(t, X_1, Y_1), (t, X_2, Y_2), \dots, (t, X_t, Y_t), Y_t \in \{0,1,2\}\}$ ，依据时序顺序，前 80% 的样本作为训练集，后 20% 的样本作为测试集。将训练集的数据随机生成样本对，输入到孪生长短时神经网络中，网络运算后输出样本对中两个样本的相似度，判断样本类型。模型迭代训练直至收敛的曲线如图 6 所示，表明孪生长短时神经网络可以学习到电气信息矩阵变量之间的依赖关系。

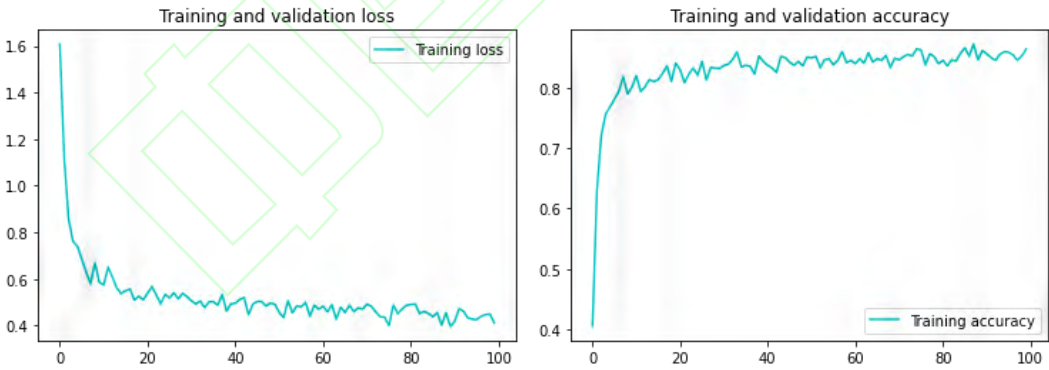


图 6 模型训练损失及精度曲线
Figure 6 Training loss and accuracy curves of the model

为选取最优的采样时间窗口，本文采用不同的窗口时间 t 开展了试验，并统计准确率，试验结果见表 3。试验结果表明，窗口时间 t 对预测的精度影响较大。对于本试验所用数据集而言，当 t 在 25~35 个时间步之间，模型预测精度较高，当 t 小于 25 或大于 35 个时间步时，预测精度逐渐下降，可以推测，该机电系统的故障与其发生前 35 小时内的电气量数据有较明显的关联。因此，本文的时间窗口 t 取 30。

表 3 模型精度与时间窗口 t 的关系

Table 3 The relationship between accuracy and time window

	t=10	t=20	t=25	t=30	t=35	t=40	t=50	t=100
Accuracy	83.83%	88.15%	91.54%	92.74%	92.50%	91.22%	88.02%	70.56%

单一的长短时神经网络同样可以完成时间序列提取和故障预测，为了验证本文提出的孪生长短时神经网络的有效性，

本文在测试集上进行了对比试验，试验结果见表 4。试验结果表明孪生长短时神经网络比单一的长短时神经网络在故障预测方面有更好的性能，一方面是因为孪生长短时神经网络通过组成样本对的方法，提高了小样本故障数据的训练利用率，另一方面，通过对比损失，保证了来自同一类的两个样本之间距离经可能小，不同类的样本之间距离经可能大，更有助于区分开样本类型。

表 4 对比试验
Table4 Contrast experiment

	长短时神经网络	孪生长短时神经网络
Accuracy	85. 61%	92. 74%

5 总结

本文基于电力系统参数对高速公路机电系统进行故障状态识别，相比基于机电设备参数和机电设备特性曲线的方法普适性更强，可以通过电力参数特征变化实现机电系统电流过载和电压过载两种故障的预测。数据来源于高速公路电力参数监控系统以每小时一次的频率采集的各回路及设备的主要电力参数，针对电力参数的时序数据特征，以及机电系统故障数据样本少、正负样本不均衡等难点，本文提出了基于孪生长短时神经网络的机电系统故障预测模型。该模型基于双层长短时神经网络进行样本时间序列特征提取，并通过孪生神功网络的样本对输入方法来提高负样本利用率。将故障状态或正常状态前一段固定长度的时间作为窗口时间，窗口时间内的电力信息矩阵作为输入变量，系统状态作为输出变量，从而将故障预测问题转化为故障分类问题。不同长度的窗口时间对模型预测结果有明显影响，针对本文数据集，窗口时间在 25~35h 时系统预测精度较高，表明该机电系统的故障发生前 35 小时内的电力数据变化特征与故障关联较大。将单一的长短时神经网络与孪生长短时神经网络进行对比试验，试验结果表明后者有更好的故障预测效果，识别准确率达到了 92.74%，表明孪生长短时神经网络的样本对及相似度度量方式有助于小样本情况下的特征学习。

参 考 文 献

[1] CHINNAM R B, BARUAH P. Autonomous diagnostics and prognostics through competitive learning driven HMM-based clustering[C]//Proceedings of the International Joint Conference on Neural Networks. Portland, OR, USA: IEEE, 2003: 2466-2471.

[2] 马海生. 高速公路机电系统运行状态自动监测系统的应用[J]. 中国新技术新产品, 2019, (14): 16-17.

[3] 朱永辉, 夏雯. 基于云平台的高速公路机电设备管理系统[J]. 中国交通信息化, 2019(3): 127-129.

[4] 尹锋, 赖清明. 高速公路信息采集智能发布系统设计研究[J]. 湖南交通科技, 2023, 49(1): 139-145.

[5] 王国辉. 高速公路机电智能化管理系统设计研究[J]. 工程技术研究, 2021, 6(5): 218-219.

[6] 王毅星. 基于深度学习和迁移学习的电力数据挖掘技术研究[D]. 杭州: 浙江大学, 2019.

[7] 王哲, 刘梓健, 邱宇. 人工智能技术在电力系统故障诊断中的应用研究[J]. 电子设计工程, 2020, 28(2): 148-151, 156.

[8] ZHANG S, BAHRAMPOUR S, RAMAKRISHNAN N, et al. Deep learning on symbolic representations for large-scale heterogeneous time-series event prediction[C]//2017 IEEE International Conference on Acoustics, Speech and Signal Processing. New Orleans, LA, USA: IEEE, 2017: 5970-5974.

[9] MARTIN C, ROCCO H, BRANDON S, et al. Climate change and power security: power load prediction for rural electrical microgrids using long short term memory and artificial neural networks[J]. Applied Sciences, 2018, 8(5): 749.

[10] KONG W, DONG Z Y, JIA Y, et al. Short-term residential load forecasting based on LSTM recurrent neural network[J]. IEEE Transactions on Smart Grid, 2017, 10(1): 841-851.

[11] GAO J, WANG H, SHEN H. Task failure prediction in cloud data centers using deep learning[J]. IEEE Transactions on Services Computing, 2020, 15(3): 1411-1422.

[12] GEORGOULOPOULOS N, HATZOPOULOS A, KARAMITSIOS K, et al. A survey on hardware failure prediction of servers using machine learning and deep learning[C]//10th International Conference on Modern Circuits and Systems Technologies (MOCASST). Thessaloniki, Greece: IEEE, 2021: 1-5.

[13] 钱子晨. 高速公路桥梁机电系统状态智慧感知技术研究[D]. 南京: 东南大学, 2021.

[14] ABOOD A M, NASSER A R, AL-KHAZRAJI H. Predictive maintenance of electromechanical systems using deep learning algorithms[J]. Ingénierie des Systèmes d' Information, 2022, 27(6): 1009-1017.

[15] 葛磊蛟, 赵康, 孙永辉, 等. 基于孪生网络和长短时记忆网络结合的配电网短期负荷预测[J]. 电力系统自动化,

2021, 45(23): 41-50.

- [16]SHERSTINSKY A. Fundamentals of recurrent neural network (RNN) and long short-term memory (LSTM) network[J]. Physica D: Nonlinear Phenomena, 2020, 404: 132306.
- [17]LIU X N, ZHOU Y, ZHAO J Q, et al. Siamese convolutional neural networks for remote sensing scene classification[J]. IEEE Geoscience and Remote Sensing Letters, 2019, 16(8): 1200-1204.
- [18]ZAGORUYKO S, KOMODAKIS N. Learning to compare image patches via convolutional neural networks[C]//2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Boston, MA, USA: IEEE, 2015: 4353-4361.
- [19]HOU S Z, GUO W, WANG Z Q, et al. Deep-learning-based fault type identification using modified CEEMDAN and image augmentation in distribution power grid[J]. IEEE Sensors Journal, 2022, 22(2): 1583-1596.
- [20]ZHANG S, BAHRAMPOUR S, RAMAKRISHNAN N, et al. Deep learning on symbolic representations for large-scale heterogeneous time-series event prediction[C]//2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). New Orleans, LA, USA: IEEE, 2017: 5970-5974.

